

SAINTS : Modélisation formelle d’une infrastructure d’identités synthétiques autonomes à topologie distribuée

SAINTS: Formal Modeling of an Autonomous Synthetic-Identity Infrastructure with Distributed Topology

Charles Mordelet¹

¹Chercheur indépendant, Orléans, France

Abstract

Local-inference language models structurally lift the supervisory bottleneck that has historically constrained influence operations. We formalize SAINTS (Synthetic Autonomous Identity Network for Targeting with Saturation), a class of infrastructure in which each persona is carried by a physically isolated node running a model fine-tuned on the persona’s behavioral profile at the weight level. SAINTS is introduced here as a formal threat model rather than an implemented or experimentally validated system : the contribution is not a deployable specification, it is a structural threat model precise enough that its breaking surfaces become analyzable. We characterize four architectural properties (non-correlation, embodied behavioral coherence, opaque action chains, saturation), formalize the cost asymmetry between deployment and investigation, and identify five detection surfaces that the architecture cannot absorb. The central analytical claim is a structural inequality : under the modelling assumptions stated, investigation cost grows super-linearly in network size while deployment cost grows linearly. We characterize a threshold parameter k^* beyond which investigation becomes, in this model, economically irrational ; its precise numerical value depends on the adversary-defender configuration and the numerical estimates given here are illustrative, not normative, and require empirical calibration. Patience, defined as waiting for unavoidable human-operator failure, appears in this analysis as one of the principal defensive vectors whose cost scales symmetrically with attacker deployment.

Keywords

modélisation de menace, opérations d’influence, identités synthétiques, LLM locaux, détection de coordination, CIB

Abstract

Le développement des modèles d’inférence locale lève structurellement le goulot d’étranglement de supervision humaine qui a historiquement contraint les infrastructures d’influence. Ce travail formalise SAINTS (*Synthetic Autonomous Identity Network for Targeting with Saturation*), une classe d’infrastructure où chaque persona est porté par un nœud physiquement isolé exécutant un modèle fine-tuné sur le profil comportemental cible au niveau des poids. SAINTS est introduit ici comme un modèle de menace formel et non comme un système implémenté ou expérimentalement validé : la contribution n’est pas une spécification d’implémentation, c’est un modèle structurel suffisamment précis pour que ses surfaces de rupture soient analysables. Quatre propriétés architecturales sont caractérisées (non-corrélation, cohérence comportementale incarnée, chaînes d’action opaques, saturation), l’asymétrie de coût entre déploiement et investigation est formalisée, et cinq surfaces de détection que l’architecture ne peut pas absorber sont identifiées. La claim analytique centrale est une inégalité structurelle : sous les hypothèses de modélisation posées, le coût d’investigation croît super-linéairement avec la taille du réseau tandis que le coût de déploiement croît linéairement. Un seuil k^* au-delà duquel l’investigation devient, dans ce modèle, économiquement irrationnelle est caractérisé ; sa valeur numérique précise dépend de la configuration adversaire-défenseur, et les estimations chiffrées présentées sont illustratives, non normatives, et requièrent une calibration empirique. La patience, définie comme l’attente de la défaillance humaine inévitable de l’opérateur, apparaît dans cette analyse comme l’un des principaux vecteurs défensifs dont le coût croît symétriquement à celui du déploiement attaquant.

CESAR’26: Computer & Electronics Security Application Rendezvous, November 18–19, 2026, Rennes, France

EMAIL: adm.charles@pm.me (C. Mordelet)



© 2026 Copyright for this paper by its author. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).

1. Introduction

La détection des campagnes d'influence coordonnée a atteint une maturité technique substantielle. Méthodes par graphe de similarité comportementale [1, 2, 3], analyse temporelle de micro-coordination [4, 5], modèles côté plateforme [6], apprentissage sur graphes dynamiques [7] : l'arsenal défensif est documenté et empiriquement efficace sur les opérations de grande échelle. Meta a neutralisé plus de deux cents réseaux coordonnés depuis 2017 ; les datasets de takedowns publiés par Twitter, Google et YouTube sont devenus les corpus de référence de la recherche.

Cette efficacité est conditionnelle. Elle repose sur une hypothèse implicite : la coordination laisse des traces (temporelles, topologiques, d'infrastructure, stylistiques). La doctrine défensive actuelle, du clustering de Pacheco *et al.* [1] au test de burstiness de Somin *et al.* [5], est construite sur la détection de ces artefacts. Ce papier modélise une classe d'infrastructure d'influence que le développement des LLM locaux (Llama 3 [8], Mistral [9], Qwen et autres familles open-weights) rend structurellement accessible et qui réduit ces artefacts à un plancher incompressible dont les résidus sont caractérisés en section 5. La méthode est offensive par nécessité : un modèle de menace incomplet produit des contre-mesures incomplètes, et décrire l'infrastructure à mi-hauteur génère un faux sentiment de couverture défensive.

Statut méthodologique. Ce papier est un *modèle de menace formel* au sens où il définit un objet architectural (quatre propriétés, contraintes, paramètres) suffisamment précis pour que ses surfaces de rupture soient analysables, sans constituer une spécification d'implémentation ni une validation empirique. Les claims chiffrés (seuil k^* , ratios de coût, valeurs de ε) sont introduits comme illustrations sous hypothèses, non comme résultats établis ; leur calibration empirique constitue un travail futur explicitement séparé. Lire ce qui suit comme une formalisation d'un objet offensif plausible destinée à exposer les surfaces de rupture, non comme la démonstration que cet objet existe au sens d'une mesure expérimentale.

L'*Internet Research Agency* (IRA) opérait avec environ quatre cents agents humains pour un budget mensuel d'environ 1,25 million de dollars [10]. Ce modèle économique impose une supervision humaine qui est précisément la source principale des artefacts détectables (variance cognitive, discontinuité temporelle, incohérences de registre sous charge), classe de variance qu'un moteur d'inférence local fine-tuné élimine par construction. Le rapport OpenAI d'octobre 2024 [11] documente plus de vingt opérations ayant tenté d'exploiter ses modèles, aucune n'ayant dépassé la catégorie 2 du *Breakout Scale* : la dépendance à une API centralisée constitue un point de défaillance unique, comme illustré par l'opération A2Z passée silencieusement immédiatement après son bannissement. Orlando *et al.* [12] montrent que des agents LLM reproduisent les signatures de coordination des opérations d'influence sans orchestration humaine. Mandiant [13] (rapport industriel à pondérer) situe 2025 comme bascule « IA-outil » → « IA-infrastructure », prolongement du cadre de Brundage *et al.* [14].

SAINTS formalise la classe d'infrastructure vers laquelle cette trajectoire converge. Le destinataire implicite est analytique : threat intelligence, plateformes de détection, cellules d'analyse cognitive et comportementale. La valeur opérationnelle du document est dans ses contraintes non résolues et ses surfaces de rupture, pas dans son architecture. Ce qui est utile à un défenseur est précisément ce que le système ne peut pas couvrir.

L'enjeu défensif dépasse la détection d'opérations individuelles. À l'échelle d'un acteur étatique, cette classe d'infrastructure ne pousse pas une narrative ponctuelle ; elle reconfigure progressivement l'arrière-plan informationnel sur lequel l'opinion publique se forme, par production cohérente et soutenue de signal synthétique à haute densité. La défense efficace ne peut donc pas être uniquement réactive : elle relève d'un engagement structurel de l'écosystème institutionnel sur l'intégrité de l'environnement informationnel partagé, dans la continuité du cadre tracé par Brundage *et al.* [14].

Organisation. Section 2 : état de l'art (opérations documentées, détection CIB, stylométrie et détection LLM). Section 3 : modèle SAINTS et ses quatre propriétés. Section 4 : asymétrie

de coût attaquant/défenseur. Section 5 : cinq surfaces de détection structurellement exposées. Section 6 : limites, contre-mesures émergentes, angles morts. Annexe A : dérivation formelle du seuil statistique.

2. État de l’art

2.1. Opérations d’influence documentées

Cinq opérations établissent le pattern d’attribution caractéristique des infrastructures pré-LLM. Aucune n’a cédé sur l’analyse comportementale des personas individuels ; toutes ont cédé sur des artefacts d’infrastructure, des erreurs humaines sous contrainte, ou des points de convergence physico-administrative.

Secondary Infektion (Russie, 2014–2020) a opéré sur plus de trois cents plateformes pendant six ans avec des comptes à usage unique [15]. L’attribution n’a pas reposé sur l’analyse des personas mais sur la corrélation de métadonnées techniques : templates de documents réutilisés, empreintes linguistiques cross-plateformes, synchronisation des séquences d’activation. Le signal était dans l’infrastructure, pas dans les identités.

Indian Chronicles (Inde, 2005–2020) constitue l’opération longue durée la plus documentée : quinze ans, deux cent soixante-cinq faux médias, accréditations aux Nations Unies, implantation institutionnelle physique réelle en Europe [16]. Sa robustesse opérationnelle exceptionnelle n’a pas résisté à l’ancrage physique. C’est précisément cet ancrage qui a fourni le fil de remontée : une adresse email centrale (`csopus[at]yahoo.com`) utilisée pour enregistrer des centaines de domaines, des adresses de bureaux virtuels réutilisées, des ONG reconstituées à partir de défunts. Plus l’opération s’ancrait dans le réel pour crédibiliser ses personas, plus elle créait de points de convergence forensiquement exploitables.

Endless Mayfly (Iran, 2016–2018) opérait des personas fonctionnels mais non incarnés [17]. Citizen Lab a identifié onze personas, soixante-douze domaines, cent trente-cinq articles fabriqués. Les attributions ont porté sur les vecteurs que constitue l’absence de cohérence comportementale longue durée : absence de drift temporel organique, patterns d’amplification trop synchrones, personas sans historique de dérive lexicale. Le réseau IUVM Press, amplifiant systématiquement le contenu Endless Mayfly, a fourni le lien structurel d’attribution.

Doppelganger (Russie, 2022–présent) clone des sites de médias majeurs via des domaines typosquattés [18]. L’attribution est venue de l’infrastructure réseau elle-même : plages IP, ASNs, JavaScript partagé entre domaines, outil Keitaro de suivi de redirections présent sur l’ensemble du parc. L’opération a survécu à de multiples expositions publiques, se reconstituant en heures après chaque takedown ; cette capacité de réponse rapide est elle-même un signal d’attribution institutionnelle.

Spamouflage (Chine, 2017–présent) est la plus grande opération cross-plateforme documentée, neutralisée répétitivement par analyse topologique de coordination [19]. Ses défaillances OPSEC sont systématiques : synchronisation de l’activité sur les horaires de bureau chinois, faible familiarité des opérateurs avec l’environnement informationnel occidental, réactivation de clusters quasi identiques après chaque takedown. Malgré une échelle massive, l’engagement organique est resté quasi nul.

Le pattern est constant. L’attribution n’a jamais reposé sur l’analyse comportementale des identités individuelles. Elle a reposé sur des artefacts d’infrastructure (IP, domaines, outils partagés), des erreurs humaines sous contrainte temporelle (adresse email réutilisée, template copié), ou des traces d’ancrage physique. Les personas eux-mêmes n’ont jamais été le vecteur primaire d’exposition. Ce constat est le point de départ de la formalisation SAINTS. Le rapport du Sénat américain sur l’IRA [10] complète cette base empirique sur la structure organisationnelle d’une opération étatique pré-LLM : quatre cents agents, supervision humaine intensive, masse salariale dominante. Les rapports OpenAI [11] et Google Threat Intelligence Group [20] documentent l’état post-LLM : toutes les opérations exploitant des modèles génératifs

via API étaient détectables précisément parce qu’elles dépendaient de l’API centralisée comme point de défaillance unique. Le passage au modèle local-inférence intégral est l’objet architectural que SAINTS formalise.

2.2. Méthodes de détection CIB

La détection de comportement inauthentique coordonné (CIB) a convergé sur trois familles de méthodes : par graphe de similarité comportementale [1, 2, 3], par analyse temporelle de co-activité [4, 5], et par modélisation côté plateforme exploitant des features non publiques inaccessibles à la recherche externe [6, 7]. Cinus *et al.* [21] étendent l’approche aux opérations cross-plateforme. Mannocci *et al.* [22] en proposent une synthèse récente.

Deux limites de cette littérature sont structurellement pertinentes pour le présent travail. Cresci *et al.* [23] montrent que les performances publiées sont systématiquement surestimées sur des datasets non représentatifs : la transposition à des comportements adversariaux non vus dans le corpus d’entraînement reste une question ouverte. Mannocci *et al.* [22] identifient comme limite centrale l’absence de *ground truth* fiable, qui rend impossible la distinction empirique entre coordination authentique et coordination inauthentique sur des fenêtres longues. Broniatowski *et al.* [24] proposent une détection inductive opérant sur des signatures abstraites de graphe plutôt que sur des campagnes préalablement vues, ce qui constitue le vecteur générique le plus prometteur. Waniek *et al.* [25] démontrent qu’il est possible de masquer les nœuds centraux d’un réseau couvert à partir d’informations locales, mais que les mesures de centralité de groupe restent exploitables : on peut masquer qui commande, on peut difficilement masquer qu’un groupe existe si sa densité interne dépasse le plancher organique.

2.3. Stylogométrie adversariale et détection de texte LLM

La stylogométrie comme outil d’attribution est une technique mature [26, 27, 28], dont la résistance à l’évasion adversariale est en revanche fragile. Sur la détection de texte généré par LLM, la trajectoire est défavorable au défenseur. DetectGPT [29] a établi un point de référence ; Pedrotti *et al.* [30] démontrent qu’un déplacement contrôlé du style d’écriture du modèle suffit à faire chuter les détecteurs ; Gu *et al.* [31] formalisent l’évasion par humanisation stylistique en boîte noire ; Zhang *et al.* [32] montrent l’impossibilité théorique de filigrane fort pour les modèles génératifs. Wu *et al.* [33] en fournissent une synthèse récente dont la conclusion opérationnelle est sans ambiguïté : les détecteurs publiés sont battus par les techniques d’évasion publiées avec un retard structurel d’environ une génération de modèles.

Sur le calibrage stylistique d’un modèle local sur un persona cible, Vyborov *et al.* [34] démontrent la faisabilité par QLoRA sur corpus d’interview ; Li *et al.* [35] montrent que le *supervised fine-tuning* (SFT) et le *direct preference optimization* (DPO) sur corpus de personnalité produisent des profils Big Five mesurables indiscernables des données humaines dans les instruments d’évaluation standard. McGovern *et al.* [36] précisent le résultat important : les LLMs laissent des empreintes morphosyntaxiques persistantes à travers les domaines, mais les modèles *instruction-tunés* sont plus faciles à détecter que les modèles de base. L’implication architecturale est directe : un fine-tuning délibéré sur style cible (et non sur la serviabilité) est la voie qui réduit la détectabilité, ce qui correspond précisément à la propriété requise par le modèle SAINTS.

2.4. Classes de preuve mobilisées

Les sources mobilisées dans cette section relèvent de trois statuts qu’il importe de ne pas confondre dans la suite. Les *faits documentés* regroupent les opérations attribuées par des organismes peer-checkables (Citizen Lab, EU DisinfoLab, DFRLab, Senate Select Committee on Intelligence) ainsi que les rapports OpenAI [11] et Google TIG [20] dont les données factuelles sont vérifiables par croisement. Les *résultats expérimentaux* regroupent les travaux peer-reviewed

mobilisant un protocole expérimental contrôlé [1, 25, 12, 34, 35, 36, 23]. Les *rapports industriels à pondérer*, dont Mandiant [13], sont mobilisés à titre d’éléments contextuels et non comme preuves formelles. Le modèle SAINTS lui-même relève d’une *inférence de modélisation* : il extrapole l’objet analytique vers lequel les sources précédentes pointent collectivement, sans validation expérimentale propre.

3. Modèle SAINTS

Définition. Un système SAINTS se compose de quatre éléments : un ensemble fini de nœuds physiquement isolés $N = \{n_1, \dots, n_k\}$; une contrainte de corrélation par paires bornée par un paramètre ε ; une collection de modèles d’inférence locaux $\{M_p\}_{p \in N}$ fine-tunés sur un profil comportemental cible B_p *sans mission opérationnelle encodée dans les poids* ; et une fonction de reprise en main HUMINT externe, dont l’intervention est ponctuelle. Les quatre sous-sections suivantes caractérisent les propriétés architecturales requises : non-corrélation (3.1), cohérence comportementale incarnée (3.2), chaînes d’action opaques (3.3), saturation passive (3.4). Chacune répond à une classe d’artefact des architectures pré-LLM en la réduisant à un plancher incompressible dont les résidus constituent les surfaces de la section 5.

3.1. Topologie distribuée et non-corrélation

Chaque nœud est une machine physique distincte. Un équipement, un modèle, une configuration, une identité. Pas d’infrastructure partagée. Pas de couche commune exploitable. L’isolation n’est pas une mesure de sécurité, c’est le principe architectural fondamental : toute mutualisation introduit une surface de corrélation.

Score de corrélation. Deux nœuds sont corrélables dès qu’ils convergent sur *au moins une dimension d’observation*. La métrique pertinente côté défenseur est donc disjonctive :

$$C(n_i, n_j) = \max(d_{\text{hw}}(n_i, n_j), d_{\text{net}}(n_i, n_j), d_{\text{temp}}(n_i, n_j), d_{\text{style}}(n_i, n_j)) \quad (1)$$

où chaque $d_{\bullet}$ mesure l’écart sur une dimension d’observation indépendante : empreinte hardware (UUID, MAC, TPM, canvas, WebGL, polices), couche réseau (origine VPN, latence, MTU), structure temporelle d’activité (rythmes circadiens, fenêtres de connexion, micro-patterns d’engagement), signature stylométrique. La forme *max* reflète l’intuition opérationnelle : un seul axe fortement corrélé suffit à l’attribution, et la métrique défensive la plus sévère gouverne donc le dimensionnement adverse. La contrainte architecturale est $C(n_i, n_j) \leq \varepsilon$ pour toute paire, par construction et non par mesure *a posteriori*.

La valeur atteignable de ε dépend directement de la discipline opérationnelle (diversité des sources d’acquisition matérielle, hétérogénéité réseau, variance temporelle et stylistique par persona). Aucun matériel grand public ne garantit $\varepsilon \rightarrow 0$: les biais méthodologiques partagés (architecture de fine-tuning, gamme de matériel disponible, biais culturel de calibrage) imposent un plancher empirique que ce papier ne quantifie pas ; sa détermination expérimentale est un travail futur prioritaire.

Déteçtabilité collective du sous-graphe synthétique. Même si chaque nœud individuel reste indiscernable de l’organique, la signature statistique du sous-graphe synthétique devient distinguable à mesure que k croît. L’intuition est directe : avec k nœuds on a $O(k^2)$ paires, ce qui augmente la puissance statistique d’un test comparant la distribution des corrélations internes du sous-graphe à celle du graphe organique. Il existe donc un seuil k_{stat}^* au-delà duquel le sous-graphe devient statistiquement détectable, fonction de ε et du niveau de test choisi. Ce seuil n’est pas une constante universelle : il dépend de la discipline opérationnelle de l’adversaire, de la puissance de test du défenseur, et de la corrélation résiduelle ε . Pour fixer un ordre de grandeur,

sous des hypothèses naïves d'indépendance des paires et un écart distributionnel résiduel de l'ordre de 0,01, le seuil se situe autour de $k_{\text{stat}}^* \approx 200$; cette valeur est strictement illustrative, explicitement *toy estimate* sous indépendance naïve, et l'annexe A montre qu'une dérivation plus rigoureuse (test à deux échantillons de Kolmogorov-Smirnov avec correction U-statistique pour la dépendance structurelle entre paires) repousse ce seuil d'un ordre de grandeur.

Discipline matérielle, temporelle et canal HUMINT (hypothèses de modélisation). Dans le modèle, l'équipement est supposé civil et acquis par sources diversifiées (un parc homogène produirait des UUIDs/MAC/TPM corrélables indépendamment de la couche logicielle). La contrainte réseau est modélisée par un tunnel avec *kill switch* permanent, l'empreinte navigateur (canvas, WebGL, polices, timezone, résolution) étant traitée comme dimension d'observation distincte du routage [24]. La structure temporelle est définie comme un cycle d'activité piloté physiquement (extinction/rallumage hardware calés sur la structure temporelle propre au persona, sans cron logiciel) ; Varol *et al.* [37] indiquent que les features temporelles figurent parmi les discriminants les plus robustes humain/automatisé. L'isolation physique stricte est modélisée comme impliquant par construction l'absence de canal d'orchestration réseau (C2) corrélable : la reprise en main par l'opérateur lors des phases actives est supposée physique, soit par accès direct à la machine, soit par dépôt distribué sur sites tiers (foyers réels, postes loués) avec déplacement de l'opérateur. Cette hypothèse plafonne la fréquence d'opérations actives et borne le ratio actifs/passifs du parc, sans signature réseau distincte du trafic banal de chaque nœud. Le modèle suppose un fine-tuning intégral sur ΔW (stylométrie, vocabulaire actif, cadres de référence, patterns d'engagement), sans *system prompt* qui constituerait une couche d'imitation ; les implications sont traitées en 3.2. La fonction opérationnelle d'un nœud est modélisée comme quasi-exclusivement passive (posts de routine, réactions, navigation organique) : le nœud sature, accumule de la crédibilité, sans engager de décision à risque, les domaines étant supposés distribués (un écosystème thématique distinct par nœud) pour maximiser la surface agrégée sans chevauchement corrélable. La crédibilité accumulée est traitée comme un actif non-récupérable : un nœud brûlé en maturation coûte peu, brûlé à maturité opérationnelle il perd l'intégralité de son historique.

Contraintes non résolues. Le fine-tuning complet sur ΔW produit un modèle qui ne se corrige pas hors de son cadre identitaire. Une dérive de contexte produit une réponse cohérente avec l'identité mais incohérente avec la réalité, non détectable depuis le nœud lui-même. La supervision externe périodique est un compromis : trop faible, dérive silencieuse ; trop élevée, surface d'intervention humaine corrélable. Une seconde contrainte borne le modèle : une identité sans historique antérieur à son déploiement présente une absence de passé corrélable, détectable dans les systèmes de scoring de crédibilité. La légende doit précéder l'activation opérationnelle ; le temps de maturation d'un nœud est un coût réel.

3.2. Cohérence comportementale incarnée

La distinction opérationnelle n'est pas entre imiter et ne pas imiter une identité, elle est entre *performer* une identité et en *être structurellement équipé*. La différence porte d'abord sur la présence ou l'absence d'un objectif explicitement injecté dans le modèle. Un *system prompt* du type « tu es Marc, défends X, évite Y » installe un cadre référent que le profiling par contrainte peut cartographier : les évitements systématiques révèlent la mission, et le persona devient analysable comme un système avec un objectif. Un fine-tuning sur ΔW qui absorbe l'identité comportementale *sans encoder de mission* ne présente pas ce cadre. Le persona ne sait pas qu'il participe à une opération parce qu'il n'y a pas d'opération encodée dans ses poids ; l'opération réside intégralement chez l'opérateur HUMINT qui reprend la main lors des phases actives. Le LLM porte l'identité, l'opérateur porte la mission. Ce découplage strict est l'objet architectural central de cette section.

Un opérateur humain exécutant un persona produit une dérive stylométrique croissante avec la charge cognitive, la fatigue et la durée opérationnelle : c’est précisément la classe de variance que le modèle réduit par construction. Vyborov *et al.* [34] démontrent la faisabilité du calibrage stylistique via QLoRA ; Li *et al.* [35] montrent que SFT et DPO sur corpus de personnalité produisent des profils Big Five indiscernables des données humaines dans les instruments d’évaluation standard. McGovern *et al.* [36] précisent le résultat clé : les modèles *instruction-tunés* sont plus faciles à détecter que les modèles de base, donc un fine-tuning délibéré sur style cible (et non sur la serviabilité) est la voie qui réduit la détectabilité.

L’absence de mission encodée rend également le persona *analytiquement inintéressant* : un humain lambda qui poste épisodiquement n’est pas profilé parce qu’aucun signal de mission ne justifie l’analyse. Ne produire aucun gradient d’objectif intelligible est une couche défensive distincte de la saturation par volume (3.4), structurellement plus puissante : la première rend le persona *inanalysable*, la seconde le rend *non analysé*. Une dégradation temporelle s’ajoute : un fine-tuning sur corpus figé produit une pertinence lexicale et culturelle qui se dégrade ; l’injection périodique de contexte contemporain est requise mais son pilotage représente une surface d’exposition humaine récurrente.

Escalation et retrieval humain. La frontière passive/active n’est pas figée : un mécanisme d’escalation interne au nœud, fondé sur la quantification d’incertitude du modèle (perplexité par token, divergence des distributions de sortie, désalignement contexte/persona), déclenche la reprise en main humaine lorsque la conversation excède le domaine de cohérence. En régime nominal le nœud opère en autonomie ; l’opérateur HUMINT consulte un référentiel comportemental externe (feuille de route persona, contraintes de registre, historique synthétique) qui constitue la fonction *retrieval-augmented* dans la boucle humaine. Le nœud n’embarque aucun retrieval automatique sur la mission, ce qui maintient la propriété de mission non-encodée dans les poids.

Contrainte résiduelle. Le découplage strict identité/mission suppose que la procédure de fine-tuning n’introduit pas de biais de mission résiduels. Si le corpus d’entraînement ou la phase de RLHF/DPO injectent implicitement des préférences alignées sur l’opération (sélection systématique de réponses en faveur d’une narrative cible), un profiling fin peut révéler ces biais comme cadre opérationnel implicite. Le découplage est une discipline de construction du corpus, pas une propriété automatique du fine-tuning [23].

3.3. Chaînes d’action opaques

Les deux propriétés précédentes traitent l’identité d’un nœud isolé. Une troisième surface subsiste au niveau de la *coordination entre nœuds* : les actions opérationnelles produisent par construction des flux observables que la fragmentation causale attaque en supprimant l’objet même de la détection.

Le chiffrement protège le contenu d’un message. La fragmentation détruit la structure de l’action elle-même. Un message chiffré intercepté révèle qu’une action a eu lieu, entre quels nœuds, à quel moment. Un fragment intercepté ne révèle rien : il ne contient pas la condition nécessaire à sa propre interprétation. La distinction est opérationnellement fondamentale et déplace le problème du contenu vers la structure causale. La plupart des outils d’attribution réseau identifient des acteurs à partir de flux de communication ; un système où les fragments d’action ne créent pas de flux entre nœuds n’est pas détecté par ces outils. Non parce qu’il est invisible : parce que l’objet de la détection n’existe pas.

Dans le modèle, l’architecture borne à deux ou trois le nombre de liens directs entre identités fictives dans une chaîne d’action. Chaque nœud ne voit qu’un fragment local, aucun ne détient une vue suffisante pour reconstruire l’action globale. Ce n’est pas de la coordination distribuée au sens technique (pas de consensus, pas de vote, pas de négociation) : c’est une fragmentation

causale où la coordination est, par hypothèse de construction, structurellement absente à chaque point d'observation individuel.

L'absence de coordination observable au niveau des actions repose sur une propriété amont : le canal d'objectifs vers les nœuds est nul par construction. Les nœuds ne reçoivent pas d'instructions opérationnelles parce que les LLM n'ont pas d'objectif opérationnel encodé (cf. 3.2). L'opérateur HUMINT porte la mission ; les LLM portent l'identité comportementale. Aucun canal d'orchestration n'est requis parce qu'aucune orchestration n'est diffusée vers les nœuds eux-mêmes ; la convergence opérationnelle émerge de la reprise en main ponctuelle, propriété cohérente avec les résultats d'Orlando *et al.* [12] sur la convergence d'agents LLM sans communication explicite.

Une action opérationnelle est décomposée en fragments distribués sur plusieurs personas opérant dans des fenêtres temporelles distinctes. Chaque fragment isolé est indiscernable d'une activité de routine lorsqu'observé sans connaissance des autres fragments. *En phase passive*, lorsque les domaines thématiques sont maintenus disjoints par construction et que les fragments sont temporellement éloignés, ils ne portent aucune information les uns sur les autres : observer un fragment isolé n'apporte aucune information sur l'action globale. *En phase active*, la convergence thématique sur la cible narrative recrée du recoupement entre domaines : ce régime constitue la surface de détection traitée en 5.3.

L'action n'est récupérable qu'avec accès à la totalité des fragments *et* l'ordonnancement temporel-causal correct, ni l'un ni l'autre n'étant disponible à un observateur ayant visibilité partielle. La fenêtre d'analyse doit s'étendre sur des mois, multipliant le volume de données sans garantie de convergence [22]. Sur cibles à évolution lente (narratives, réputations), des fenêtres de plusieurs mois sont opérationnellement viables sans dégradation d'efficacité.

La distinction avec le masquage actif est structurelle : un signal masqué reste récupérable si le masque cède, un signal dissous n'existe plus comme objet isolable. Endless Mayfly [17] a échoué sur ce point précis : les patterns d'amplification trop synchrones produisaient des pics temporels que la dilution par routine quotidienne à haute densité est conçue pour éviter. Chaque fragment est encadré d'activité banale ; le persona maintient sa routine avant, pendant et après l'acte opérationnel.

Les chaînes d'action opaques (OAC) constituent également le vecteur HUMINT le plus sobre de l'infrastructure. Personas répartis dans des domaines distincts, validation mutuelle, liens croisés avec des acteurs réels : la frontière entre réseau synthétique et réseau organique devient analytiquement imperméable. L'effet d'échelle est non-linéaire : cinquante identités validant mutuellement via des acteurs réels produisent un poids d'influence structurellement différent de la somme de leurs influences individuelles, par émergence topologique.

Contrainte non résolue. La validation mutuelle entre personas fictifs reste efficace tant que la densité de liens fictif/fictif reste sous le seuil de détection des algorithmes de clustering communautaire. Au-delà d'un certain ratio, le sous-graphe synthétique devient statistiquement distinguable du graphe organique, non par analyse individuelle des nœuds mais par analyse topologique du réseau de validation lui-même. Waniek *et al.* [25] formalisent ce résultat : on peut masquer qui commande, on peut difficilement masquer qu'un groupe existe si sa densité interne dépasse le plancher organique. Cinus *et al.* [21] montrent que 75% d'un réseau coordonné reste actif après suspension partielle, révélant à la fois la résilience et la continuité topologique exploitable. La coordination en fenêtre temporelle courte produit une surface de corrélation non nulle : les OAC sont robustes à proportion inverse de la contrainte temporelle de l'opération.

3.4. Mécanique de saturation

Tout est loggé, mais l'analyse exhaustive ne l'est pas : les agences ne cherchent pas à analyser la masse, elles cherchent ce qui en émerge. La saturation agit sur la décision d'analyser, pas sur la capacité : ne jamais entrer en file de révision est structurellement différent de résister à

l’analyse. Le mécanisme opère à deux niveaux articulés. Au niveau du nœud, l’objectif est de *traverser sans friction* : le persona ne produit aucun gradient d’extraction parce qu’il génère exactement le bruit attendu pour son profil. Au niveau du parc, k nœuds produisant chacun du bruit normal contribuent à élever le plancher de bruit ambiant sur les sujets cibles, ce qui rend leurs propres fragments opérationnels d’autant moins distinguables.

Soit chaque nœud i produisant du contenu de routine au taux R_i et du contenu opérationnel au taux O_i . Le ratio signal-bruit opérationnel par compte (SNR, *signal-to-noise ratio*) doit rester sous le seuil de détection θ du système de scoring :

$$\text{SNR}_i = \frac{O_i}{R_i + N_{\text{amb}}} < \theta \quad (2)$$

où N_{amb} est l’activité organique ambiante sur le sujet. Le débit opérationnel maximal est scalable linéairement avec le plancher de bruit et avec l’activité de routine du nœud. La valeur de θ n’est pas universelle : elle dépend de la sophistication du pipeline de scoring, de la capacité de révision humaine, et de la priorité accordée au contexte cible. Un sujet politiquement sensible en période électorale concentre des ressources qui abaissent θ ; le dimensionnement doit donc être calibré sur le θ le plus contraignant parmi les cibles envisagées. À l’échelle d’une plateforme majeure ($\sim 10^9$ utilisateurs), une réduction même faible du seuil de file génère des millions de faux positifs dépassant la capacité d’analyse humaine : la défense n’est pas que les nœuds résistent à l’analyse, c’est qu’ils n’entrent jamais dans la file.

Se cacher produit une absence localisée qui est un signal. L’opération correcte est l’inverse : produire exactement le bruit attendu, avec la densité attendue, dans les registres attendus pour un profil de cette classe. La surface de détection réelle réside dans les statistiques de second ordre (structure de corrélation entre posts, micro-timing, patterns de réponse à des stimuli externes) ; leur résolution imparfaite constitue une surface d’exposition persistante (voir section 5).

Contrainte non résolue. Le modèle suppose la stabilité des seuils d’extraction ; un système défensif à apprentissage continu peut abaisser ces seuils sans signal préalable, transformant la saturation en vecteur d’entraînement adversarial (cas non traité ici). Surtout, la saturation au premier ordre (volume/SNR) ne couvre pas la convergence sémantique inter-nœuds en mode actif, surface distincte traitée en section 5 (5.3).

4. Asymétrie de coût analytique

Le coût de déploiement d’un nœud se décompose en quatre postes : équipement grand public à usage unique, connectivité récurrente, calcul de fine-tuning du modèle, et investissement temporel en maturation d’identité pré-opérationnelle. Le coût marginal du k -ième nœud est approximativement constant ; l’absence d’infrastructure partagée élimine tout overhead de montée en charge à l’exception du temps de maturation. Le coût total croît donc linéairement en k .

Le coût d’investigation est structurellement différent. Il se décompose en trois composantes. D’abord, le coût pour signaler un nœud comme suspect, qui exige soit d’abaisser le seuil de scoring (au prix de millions de faux positifs à 10^9 utilisateurs), soit de disposer d’un signal de renseignement externe. Ensuite, le coût pour relier deux nœuds identifiés, qui dans le pire cas (sans signal de départ) requiert $O(k^2)$ tests par paires sur des nœuds satisfaisant la contrainte (1), ramené à $O(k \log k)$ via *seed expansion* à partir d’un nœud-graine compromis. Enfin, le coût pour attribuer le réseau à un opérateur, qui exige de franchir l’*air-gap* entre couche d’orchestration et couche d’exécution, réalisable par construction uniquement via défaillance humaine.

Piercey *et al.* [38] documentent ce *bottleneck* quadratique à l’échelle Reddit : la computation de toutes les similarités par paires d’auteurs est infaisable à grande échelle même avec des projections efficaces. L’analyse défensive ne se fait jamais en pire cas brut ; les pipelines réels

reposent sur du clustering hiérarchique, du graph embedding et de la détection de communautés inductive [24]. Le régime de coût opérationnel se situe donc plutôt en $O(k \log k)$ que $O(k^2)$. Dans le modèle, l’asymétrie reste favorable à l’attaquant (le défenseur paie un facteur logarithmique que l’attaquant ne paie pas), mais elle est moins spectaculaire que ne le suggère le pire cas naïf et requiert calibration empirique pour être quantifiée.

Inégalité analytique centrale. Sous les hypothèses précédentes, le coût d’investigation croît plus vite que linéairement en k tandis que le coût de déploiement croît linéairement en k : ceci suggère l’existence d’un seuil k^* au-delà duquel l’investigation deviendrait, dans ce modèle, économiquement irrationnelle :

$$k^* : \frac{C_{\text{inv}}(k^*)}{P(\text{succès})} > \text{Budget}_{\text{def}} \quad (3)$$

Le symbole k^* apparaît dans deux acceptions liées. Le seuil statistique k_{stat}^* de la section 3 (annexe A) marque la borne de *délectabilité* du sous-graphe synthétique sous test statistique, indépendante du budget. Le seuil économique k_{eco}^* ci-dessus marque la borne d’*actionnabilité* : au-delà, l’investigation deviendrait irrationnelle au regard du budget défenseur. Pour que l’infrastructure soit viable dans le modèle, l’attaquant doit opérer dans la fenêtre $k_{\text{eco}}^* < k_{\text{op}} < k_{\text{stat}}^*$: suffisamment grand pour que le défenseur ne s’engage pas, suffisamment petit pour que la signature collective ne déclenche pas le test. L’existence effective de cette fenêtre dépend des paramètres opérationnels et n’est pas garantie ; sa caractérisation empirique est un travail futur. Sauf indication contraire, k^* désigne dans la suite le seuil économique.

Ordres de grandeur indicatifs IRA / SAINTS. L’IRA opérait avec environ 1,25 M\$/mois pour 400 agents humains [10], dominée par la masse salariale qui est aussi la source principale de la variance détectable. Une infrastructure SAINTS du même ordre de taille présenterait, sous les hypothèses du modèle, un profil de coût qualitativement différent : matériel grand public dispersable, connectivité récurrente modérée, fine-tuning par persona via QLoRA à coût marginal faible [39], maturation en temps plutôt qu’en capital récurrent. Le poste opérateur HUMINT, dimensionné par le débit d’opérations actives et non par k , reste borné par une équipe restreinte. Cette comparaison indique une asymétrie plausible plutôt qu’un ratio établi : sa quantification effective requiert une calibration empirique non conduite ici.

Invariance d’échelle économique. L’asymétrie reste structurellement invariante d’échelle parce que le budget défensif s’ajuste à la menace perçue : un déploiement modeste n’attire pas une investigation soutenue, un déploiement étatique en attire une dimensionnée à proportion. La fenêtre opérationnelle $k_{\text{eco}}^* < k_{\text{op}} < k_{\text{stat}}^*$ se reproduit donc à chaque palier d’enjeu, par construction. Le profil technique des surfaces dominantes varie en revanche avec l’échelle : la trace physico-financière (5.5) domine à petite échelle, la densité topologique (5.2) prend le relais à grande échelle, sans modifier la structure de l’asymétrie.

5. Surfaces de détection structurellement exposées

L’infrastructure est stratégiquement robuste. Elle n’est pas structurellement indestructible. Les surfaces qui suivent ne sont pas des failles d’implémentation corrigeables : ce sont des propriétés incompressibles de l’architecture, des contraintes permanentes que le modèle ne peut pas absorber. Cette section les caractérise dans l’ordre de leur exploitabilité analytique décroissante.

5.1. Régularité paradoxale

Un persona parfaitement cohérent produit une variance comportementale réduite. Un humain réel produit une variance composite, agrégeant variance de base, variance de contexte, variance

émotionnelle et bruit. Si la variance du persona est systématiquement inférieure à celle de l'organique, l'absence de variance est elle-même un signal de second ordre. Le test associé est direct : pour un ensemble de comptes U , signaler ceux dont le coefficient de variation des features comportementales se situe dans la queue inférieure de la distribution organique, $CV(features) < q_\alpha(CV_{org})$, où q_α est le α -quantile de la distribution organique.

Ariyaratne *et al.* [40] proposent BLOC (*Behavioral Languages for Online Characterization*), une représentation des comportements de compte comme chaînes symboliques segmentées dans le temps dont le changement entre segments consécutifs constitue un signal résistant à l'évasion. Les comptes en opération d'influence dans une même campagne montrent des distributions de changement comportemental anormalement similaires, tandis que les comptes authentiques montrent des distributions indépendantes. C'est une contrainte fondamentale de l'architecture : les événements parasites contribuent à l'alibi organique d'une identité ; leur suppression systématique produit une cohérence trop propre, décelable par les mêmes outils qu'elle cherche à tromper. Le seuil de variance tolérable sans qu'elle devienne vecteur d'attribution est un paramètre de calibrage, pas une propriété émergente.

L'implication pratique : l'injection calibrée de variance non-opérationnelle est nécessaire, mais sa calibration optimale est non triviale : trop produit le signal d'imitation, trop peu produit la régularité paradoxale. Pour ordre de grandeur (estimations indicatives de l'auteur dérivées de la littérature sur la détection de bots [37, 23], non issues d'un dataset unique de référence), sur trois features comportementales (délai inter-posts, type-token, engagement hebdomadaire), le CV organique typique se situe dans $[0,4; 1,2]$ avec $q_{0,05} \in [0,15; 0,40]$; un nœud sans injection produit des CV attendus de 0,05 à 0,12, systématiquement sous $q_{0,05}$. La fenêtre viable est étroite : un déficit ou excès de 10–15% par rapport au seuil organique replace le compte dans une queue détectable. Varol *et al.* [37] documentent que les features les plus discriminantes pour la détection de bots sont précisément les séries temporelles d'activité et les patterns d'engagement réseau, c'est-à-dire celles que SAINTS calibre individuellement sur chaque persona. Cresci *et al.* [23] montrent par ailleurs que les performances publiées des détecteurs comportementaux sont systématiquement surestimées sur des datasets non représentatifs, et que leur transfert à des comportements adversariaux non vus en entraînement reste une question ouverte : la détection par variance reste donc, à ce jour, un vecteur dont l'efficacité opérationnelle réelle à grande échelle n'est pas établie. C'est la surface où le modèle est le plus vulnérable à l'échelle individuelle, et la moins exploitée en pratique.

5.2. Densité topologique du sous-graphe de validation

Pour le réseau de validation mutuelle, la densité du sous-graphe synthétique S est $\rho_S = |E_S| / \binom{|S|}{2}$ et la densité attendue d'un sous-graphe aléatoire de taille $|S|$ tiré du réseau organique est $\rho_O(|S|)$. La condition de détection est $\rho_S \gg \rho_O(|S|)$: une communauté artificiellement dense signale un sous-graphe non organique. La contrainte structurelle est que les liens synthétique/synthétique doivent rester suffisamment peu denses pour que $\rho_S \approx \rho_O(|S|)$, ce qui borne par le bas le temps de maturation du réseau. Une construction de crédibilité rapide exige une validation croisée dense ; cette validation croisée densifie ρ_S vers la détectabilité.

Le pattern est récurrent dans les opérations CIB documentées par Graphika et le Stanford Internet Observatory [19] : structure topologique distribuée correcte, densité interne du sous-graphe de validation excédant le plancher organique, détection par analyse de densité plutôt que par contenu individuel. Waniek *et al.* [25] définissent la limite théorique du camouflage topologique : on peut masquer qui commande, on peut difficilement masquer *qu'un groupe existe* si sa densité interne dépasse le plancher organique. La tension est structurellement irréductible : vitesse de montée en crédibilité et résistance à la détection topologique sont en opposition directe. Ralentir la maturation est la seule résolution, à un coût opérationnel réel.

Variante topologique spectrale. Une borne alternative au test de Kolmogorov-Smirnov de l'annexe A repose sur l'écart spectral du sous-graphe synthétique : la concentration des valeurs propres du Laplacien autour des modes de la communauté synthétique fournit un test plus directement topologique, conservant la structure de graphe que le test sur distribution de paires agrège. Cette piste, naturelle pour la détection de communautés cachées, constitue une direction d'amélioration formelle de la borne sans modification du modèle de menace présenté ici.

5.3. Convergence sémantique sous charge

En mode opérationnel actif, les nœuds convergent thématiquement sur la cible de l'opération, créant un gradient sémantique inter-nœuds absent en phase passive. La fragmentation OAC limite la corrélation *opérationnelle* observable au niveau des actions, mais ne supprime pas la convergence *thématique* inhérente à une cible commune. Cinquante nœuds activés pendant une semaine sur une narrative unique génèrent une distribution sémantique inter-nœuds anormalement homogène sur cette fenêtre : propriété structurelle de l'opérationnel, pas artefact de méthode.

Le test associé est l'analyse de la distribution sémantique inter-nœuds par fenêtre temporelle, comparée à un baseline de variance organique sur le même sujet. Sa résolution opérationnelle pose un problème ouvert qui n'est pas tranché ici : la construction d'un baseline représentatif requiert une connaissance fine de la distribution organique sur le sujet cible, qui dépend du sujet et du contexte. Cette surface est exploitable mais coûteuse en pré-requis analytiques.

5.4. Vecteur humain et fatigue OPSEC

Le LLM maintient le persona avec une cohérence que l'humain ne peut pas égaler sur durée longue. L'inverse est vrai dès que l'opération bascule en mode actif. L'humain qui reprend la main n'est pas le persona : il connaît le persona, sa stylométrie, ses habitudes, ses références, mais il les applique sous charge cognitive, contrainte temporelle, dans un contexte imprévisible. La dérive est non-intentionnelle. Elle n'en est pas moins détectable. Un opérateur par identité est une contrainte non-négociable ; un programme multi-identités produirait une désynchronisation par économie d'attention. L'ajout d'un garde-fou (référentiel persona consultable, contraintes de registre explicites, protocoles d'intervention) réduit la dérive mais introduit une surface documentaire. Ce compromis n'a pas de résolution propre.

La fatigue OPSEC aggrave ce vecteur sur durée longue : la discipline stricte du démarrage se normalise, les protocoles deviennent habitudes puis raccourcis puis artefacts. Dégradation statistiquement inévitable à l'échelle d'un parc d'opérateurs, qui ne se résout que par rotation et compartimentation. SAINTS supprime le point de défaillance unique de l'API centralisée [11, 20] en le déplaçant sur la chaîne d'opérateurs HUMINT, maillon faible structurel exploité par la patience défensive (section 6).

5.5. Trace physique et financière

Une infrastructure sans ancrage physique est crédible jusqu'à un certain seuil d'interaction. Au-delà, l'absence d'existence physique vérifiable devient signal pour un détecteur humain compétent. Les ancres institutionnelles réelles augmentent la crédibilité des personas mais créent simultanément des points de convergence physique exposés ; un seul point compromis suffit à fournir le fil qui permet de remonter. Ce risque n'est pas symétrique et ne se résout pas architecturalement, il est contextuel, fonction de la profondeur opérationnelle souhaitée.

L'infrastructure physique laisse également une trace financière : matériel, abonnements, licences. Une perquisition commence souvent par la comptabilité, non par le réseau. La diversification des sources d'acquisition répond à la corrélation d'empreinte hardware ; elle ne

répond pas à la corrélation financière, qui exige une discipline d'achat distincte. Indian Chronicles [16] et Secondary Infection [15] ont précisément cédé sur cette classe de trace périphérique non-modélisée par l'architecture nominale.

5.6. Synthèse : actionnabilité par acteur défensif

Les cinq surfaces ne sont pas symétriquement actionnables. Chaque acteur défensif dispose d'un sous-ensemble de capacités qui rend certaines surfaces opérables et d'autres inertes. Le tableau 1 synthétise cette répartition. L'objectif n'est pas de prescrire un pipeline complet, mais de permettre à chaque acteur de prioriser les surfaces sur lesquelles ses capacités propres ont une prise réelle.

Table 1

Actionnabilité des cinq surfaces par type d'acteur défensif.

Surface	Plateforme	CERT/SOC	Renseignement	LEA/Judiciaire
5.1 Régularité paradoxale	Test queue inf. Scoring auto.	CV. Coopération plateforme requise.	Partenariat plateforme sur cibles pré-identifiées.	Non actionnable.
5.2 Densité topologique	Analyse graphe communautaire, sous-graphes denses.	OSINT graphes publics. Profondeur limitée.	Corrélation multi-plateforme institutionnelle.	Non actionnable.
5.3 Convergence sémantique	Cross-comptes temps réel, données internes.	NLP corpus publics. Signal faible.	Narrative vs objectifs géopolitiques.	Non actionnable.
5.4 Vecteur humain	Surveillance passive longue durée.	Capitalisation inter-incidents, IoC.	HUMINT, <i>Vecteur principal</i> .	Exploitation d'erreurs documentées.
5.5 Trace physico-fin.	Pas d'accès financier.	Pas de levier direct.	Surveillance financière, acquisitions.	Perquisition comptable. <i>Vecteur principal</i> .

Aucun acteur ne couvre seul l'ensemble des surfaces : plateforme sur 5.1–5.3, judiciaire sur 5.5, renseignement sur 5.4. Toute stratégie défensive efficace est par construction inter-institutionnelle.

6. Limites du modèle et trajectoire

La première limite est épistémique : un analyste qui ne modélise pas cette classe de menace ne cherche pas ce qu'il ne conçoit pas. L'imperméabilité repose en partie sur cette asymétrie de représentation, que ce papier réduit. Avant d'attaquer le réseau, on attaque la vraisemblance : le périmètre des suspects se réduit rapidement par corrélation des capacités requises avec les acteurs connus, mais sans déclencheur externe l'entonnoir reste ouvert. La trace financière est résolue avant déploiement par toute agence dispersant les acquisitions. L'analyse comportementale de second ordre (5.1) est théoriquement valide mais opérationnellement inutilisable sans signal préalable : 10^9 comptes pour un pattern faible, c'est chercher du bruit dans du bruit. L'analyse topologique du sous-graphe de validation reste le vecteur le plus solide (elle opère sur la structure, pas le contenu) mais exige un accès plateforme direct. Le stimulus de contrainte ciblé n'est valide que si un suspect existe déjà : il confirme, il ne détecte pas.

Contre-mesures émergentes. Plusieurs trajectoires défensives, si elles se généralisent, modifient structurellement l'équation. La preuve d'humanité (*proof-of-personhood*, World ID et apparentés) impose une vérification biométrique liée à un identifiant unique, ce qui rompt la propriété de non-corrélation à la racine : deux nœuds ne peuvent pas présenter deux humains distincts si la vérification est centralisée. L'attestation device-level (App Attest, Play Integrity) lie l'identité de plateforme à une empreinte matérielle vérifiée par le constructeur, réduisant la diversité matérielle à un identifiant fournisseur. Les obligations KYC sur certaines plateformes

régulées (*Digital Services Act* en Europe pour certains usages) déplacent le coût d’acquisition d’identité de l’ordre de grandeur du matériel à l’ordre de grandeur de l’usurpation civile. La signature de contenu (C2PA) ne contraint pas le persona mais réduit la valeur opérationnelle du contenu généré qui n’en est pas pourvu. Aucune de ces couches n’est universellement déployée en 2026 ; leur adoption simultanée par les plateformes majeures rendrait SAINTS structurellement non-viable dans sa forme actuelle. La fenêtre opérationnelle de cette classe d’infrastructure est donc également bornée par la trajectoire défensive d’authentification, dont le rythme d’adoption est le paramètre dimensionnant non modélisé ici.

Domaine de validité. Le modèle SAINTS est dimensionné pour des cibles à évolution lente (narratives durables, réputations, climat informationnel ambiant). Les opérations à haute synchronicité, par exemple un pic narratif sur fenêtre courte (J-7 d’un scrutin), saturent rapidement la contrainte d’un opérateur par identité en mode actif et sortent du domaine de validité du modèle. Ce régime relève d’architectures hybrides distinctes, non couvertes ici.

Trajectoire confirmée. Orlando *et al.* [12] confirment expérimentalement que des agents LLM génératifs reproduisent sans orchestration humaine les signatures de coordination des opérations réelles : les campagnes futures peuvent ne requérir qu’une diffusion d’objectifs, supprimant la surface de communication détectable. SAINTS n’est pas hypothétique ; les composants sont disponibles et leur assemblage suit une trajectoire documentée [11, 20, 13].

Travaux futurs prioritaires. (i) Simuler la détectabilité du sous-graphe en fonction de (k, ρ_S) pour dériver empiriquement la courbe $k^* \rightarrow P(\text{détection})$; le cadre d’Orlando [12] fournit un point de départ. (ii) Formaliser la dynamique attaquant/défenseur en jeu répété à information incomplète, intégrant les stratégies de patience symétriques. (iii) Modéliser la sensibilité aux contre-mesures d’authentification et caractériser le seuil d’adoption au-delà duquel l’asymétrie bascule en faveur du défenseur.

7. Conclusion

L’intérêt analytique de SAINTS est de montrer qu’une classe d’infrastructure peut, sous certaines hypothèses réalistes, déplacer la détection vers un régime de coût et de surfaces résiduelles défavorable au défenseur. Le seuil k^* (éq. 3), au-delà duquel le coût d’investigation dépasserait les budgets défenseurs rapporté à la probabilité de succès, est l’objet analytique central ; sa valeur numérique reste à établir empiriquement, les estimations proposées étant illustratives et conditionnelles aux hypothèses sur ε et sur la fonction de succès. En deçà de k^* , une investigation ciblée demeure plausible avec signal de départ externe ; au-delà, dans le modèle, la stratégie rationnelle se déplace vers la veille longue durée sur défaillance humaine.

Trois implications opérationnelles directes. Premièrement, les méthodes de détection actuelles (similarité comportementale, micro-coordination temporelle, scoring plateforme) restent valides mais cessent d’être suffisantes : leur hypothèse fondatrice (la coordination laisse des traces corrélables) est précisément la propriété que SAINTS minimise structurellement à un plancher incompressible. Le passage aux statistiques de second ordre (variance comportementale, corrélations inter-comptes, densité topologique) n’est pas une optimisation : c’est un changement de paradigme. Deuxièmement, la patience est, parmi les vecteurs identifiés dans ce travail, celui dont le coût croît symétriquement à celui du déploiement attaquant. C’est là que les infrastructures de ce niveau ont historiquement cédé : Secondary Infection par la réutilisation de templates et de credentials cross-plateformes, Indian Chronicles par l’adresse email centrale (`csopus[at]yahoo.com`), l’IRA par des contacts traçables. Troisièmement, le travail analytique le plus rentable n’est pas l’investigation de comptes individuels mais la cartographie des surfaces

structurellement exposées (section 5), la quantification de k^* par configuration, et l'allocation entre acteurs défensifs : aucun ne couvre seul l'ensemble des cinq surfaces (table 1), toute stratégie défensive efficace contre cette classe d'infrastructure est par construction inter-institutionnelle.

La limite structurelle de cette classe d'infrastructure n'est pas dans ses composantes techniques, toutes disponibles et en amélioration constante, mais dans le facteur humain de contrôle qu'elle ne peut pas éliminer. À l'échelle d'un acteur étatique, la classe SAINTS opère à un niveau qualitativement différent de l'opération d'influence classique : elle ne pousse pas une narrative ponctuelle, elle reconfigure progressivement l'arrière-plan informationnel sur lequel l'opinion publique se forme. La défense efficace ne peut donc pas être uniquement réactive ; elle relève d'un engagement structurel et inter-institutionnel sur l'intégrité de l'environnement informationnel partagé. La caractérisation formelle de l'effet émergent à grande échelle, et la simulation paramétrique de la fenêtre opérationnelle, constituent les travaux futurs prioritaires.

Déclaration d'usage d'IA générative

Conformément à la politique CEUR-WS sur les outils d'IA générative, en vigueur depuis le 1^{er} janvier 2025, dont la déclaration est devenue obligatoire à partir du 1^{er} juin 2025¹, et à la taxonomie associée², l'auteur déclare l'usage des outils suivants dans le pipeline de production : Claude (Anthropic), Qwen (Alibaba) en configuration multi-agents, et Perplexity. Les catégories d'usage applicables au sens de la taxonomie CEUR-WS sont : *Drafting content*, *Paraphrase and reword*, *Improve writing style*, *Generate literature review*, *Citation management* et *Formatting assistance*. Les insights conceptuels du modèle SAINTS, son architecture, l'identification des surfaces de détection et leur articulation à la littérature relèvent intégralement de l'auteur, qui assume la responsabilité scientifique de l'ensemble du contenu.

A. Dérivation formelle du seuil statistique k_{stat}^*

Soit S et O les ensembles de paires de nœuds synthétiques et organiques. Sous H_0 les corrélations internes du sous-graphe synthétique suivent la distribution organique ; sous H_1 la contrainte $C(n_i, n_j) \leq \varepsilon$ décale la distribution vers les valeurs faibles. Le test de Kolmogorov-Smirnov à deux échantillons rejette H_0 au niveau α lorsque $D_{\text{KS}}(P_S, P_O) > \delta_\alpha$.

Approximation naïve sous indépendance. Avec $n_1 = \binom{k}{2}$ paires synthétiques et $n_2 \gg n_1$ paires organiques, la valeur critique à $\alpha = 0,05$ se simplifie en $\delta_{0,05}^{\text{naïf}} \approx 1,36/\sqrt{n_1}$, soit $\approx 0,039$ pour $k = 50$, $\approx 0,010$ pour $k = 200$, $\approx 0,004$ pour $k = 500$.

Correction U-statistique. Les paires partagent des nœuds : D_{KS} est en réalité une U-statistique d'ordre 2 dont la variance asymptotique est dominée par la dépendance entre paires de sommet commun. La taille effective d'échantillon est $n_{\text{eff}} = O(k)$, non $n_1 = O(k^2)$. La valeur critique corrigée devient $\delta_\alpha^{\text{corr}} \approx 1,36/\sqrt{k}$; comparée à $\delta_\alpha^{\text{naïf}} \approx 1,36\sqrt{2}/k$, le ratio vaut $\sqrt{k}/2$. Pour $k = 200$, la marge réellement tolérée est environ dix fois supérieure au calcul naïf.

L'estimation illustrative $k_{\text{stat}}^* \approx 200$ du corps de papier suppose $D_{\text{KS}} \approx 0,01$ et la borne naïve. Sous la correction U-statistique, le seuil est repoussé d'un facteur $\sqrt{k}/2$, ce qui multiplie en pratique k_{stat}^* par un ordre de grandeur.

References

- [1] D. Pacheco, P.-M. Hui, C. Torres-Lugo, B. T. Truong, A. Flammini, F. Menczer, Uncovering coordinated networks on social media: Methods and case studies, in: Proc. AAAI ICWSM, 2021. doi:10.1609/icwsm.v15i1.18075.
- [2] L. Luceri, V. Panté, K. Burghardt, E. Ferrara, Unmasking the web of deceit: Uncovering coordinated activity to expose information operations on twitter, in: Proc. ACM Web Conference (WWW), 2024. doi:10.1145/3589334.3645529.

¹<https://ceur-ws.org/GenAI/Policy.html>

²<https://ceur-ws.org/GenAI/Taxonomy.html>

- [3] F. Giglietto, N. Righetti, L. Rossi, G. Marino, It takes a village to manipulate the media: coordinated link sharing behavior during 2018 and 2019 italian elections, *Information, Communication & Society* 23 (2020). doi:10.1080/1369118X.2020.1739732.
- [4] L. Iannucci, E. Muratore, A. Matakos, M. Kivelä, Detecting coordinated activities through temporal, multiplex, and collaborative analysis, arXiv:2512.19677 (2025). doi:10.48550/arXiv.2512.19677.
- [5] S. Somin, T. Cohen, J. Kepner, A. Pentland, Echoes of the hidden: Uncovering coordination beyond network structure, arXiv:2504.02757 (2025). doi:10.48550/arXiv.2504.02757.
- [6] Meta Transparency, Adversarial threat reports, 2019–2024, <https://transparency.fb.com/metasecurity/threat-reporting>, 2024.
- [7] B. He, Y. Yang, Q. Wu, et al., BotDGT: Dynamicity-aware social bot detection with dynamic graph transformers, arXiv:2404.15070 (2024). doi:10.48550/arXiv.2404.15070.
- [8] Llama Team, AI @ Meta, The Llama 3 herd of models, arXiv:2407.21783 (2024). doi:10.48550/arXiv.2407.21783.
- [9] A. Q. Jiang, A. Sablayrolles, A. Mensch, et al., Mistral 7B, arXiv:2310.06825 (2023). doi:10.48550/arXiv.2310.06825.
- [10] US Senate Select Committee on Intelligence, Russian Active Measures Campaigns and Interference in the 2016 US Election, Volume 2, Technical Report, 2019. URL: <https://www.intelligence.senate.gov/wp-content/uploads/2024/08/sites-default-files-documents-report-volume2.pdf>.
- [11] OpenAI, Influence and Cyber Operations: An Update, Technical Report, 2024. URL: https://cdn.openai.com/threat-intelligence-reports/influence-and-cyber-operations-an-update_October-2024.pdf.
- [12] G. M. Orlando, J. Ye, V. La Gatta, M. Saeedi, V. Moscato, E. Ferrara, L. Luceri, Emergent coordinated behaviors in networked LLM agents: Modeling the strategic dynamics of information operations, in: *Proc. ACM Web Conference (WWW)*, 2026. doi:10.1145/3774904.3792580.
- [13] Mandiant / Google Cloud, AI Risk and Resilience: A Mandiant Special Report, Technical Report, 2026. URL: <https://cloud.google.com/security/resources/ai-risk-and-resilience>.
- [14] M. Brundage, S. Avin, J. Clark, et al., The Malicious Use of Artificial Intelligence: Forecasting, Prevention, and Mitigation, Technical Report, 2018. doi:10.48550/arXiv.1802.07228.
- [15] Graphika and EU DisinfoLab and DFRLab, Secondary Infektion, Technical Report, 2020. URL: <https://secondaryinfektion.org/downloads/secondary-infektion-report.pdf>.
- [16] EU DisinfoLab, Indian Chronicles: Deep Dive into a 15-Year Operation Targeting the EU and United Nations, Technical Report, 2020. URL: <https://www.disinfobservatory.org/download/26544>.
- [17] Citizen Lab, Burned After Reading: Endless Mayfly’s Ephemeral Disinformation Campaign, Technical Report, 2019. URL: <https://citizenlab.ca/2019/05/burned-after-reading-endless-mayflys-ephemeral-disinformation-campaign>.
- [18] EU DisinfoLab and Qurium, Doppelganger, Technical Report, 2022. URL: <https://www.disinfo.eu/doppelganger-hub/>.
- [19] Graphika, Spamouflage Breakout, Technical Report, 2023. URL: <https://graphika.com/reports/spamouflage-breakout>.
- [20] Google Threat Intelligence Group, Adversarial Misuse of Generative AI, Technical Report, 2025. URL: <https://cloud.google.com/blog/topics/threat-intelligence/adversarial-misuse-generative-ai>.
- [21] F. Cinus, M. Minici, L. Luceri, E. Ferrara, Exposing cross-platform coordinated inauthentic activity in the run-up to the 2024 U.S. election, in: *Proc. ACM Web Conference (WWW)*, 2025. doi:10.1145/3696410.3714698.
- [22] L. Mannocci, M. Mazza, A. Monreale, M. Tesconi, S. Cresci, Detection and characterization of coordinated online behavior: A survey, arXiv:2408.01257 (2024). doi:10.48550/arXiv.2408.01257.
- [23] S. Cresci, K.-C. Yang, A. Spognardi, et al., Demystifying misconceptions in social bots research, arXiv:2303.17251 (2025). doi:10.48550/arXiv.2303.17251.
- [24] D. A. Broniatowski, N. Gabriel, N. Johnson, Inductive detection of influence operations via graph learning, *Scientific Reports* 13 (2023) 22571. doi:10.1038/s41598-023-49676-z.
- [25] M. Waniek, T. P. Michalak, M. Wooldridge, T. Rahwan, How members of covert networks conceal the identities of their leaders, *ACM Transactions on Intelligent Systems and Technology* 13 (2021) Article 12. doi:10.1145/3490462.
- [26] M. Brennan, R. Greenstadt, Practical attacks against authorship recognition techniques, in: *Proc. 21st Innovative Applications of Artificial Intelligence Conference (IAAI-09)*, 2009, pp. 60–65.
- [27] M. Brennan, S. Afroz, R. Greenstadt, Adversarial stylometry: Circumventing authorship recognition to preserve privacy and anonymity, *ACM TISSEC* 15 (2012). doi:10.1145/2382448.2382450.
- [28] R. Overdorf, R. Greenstadt, Blogs, twitter feeds, and reddit comments: Cross-domain authorship attribution, *Proceedings on Privacy Enhancing Technologies* 2016 (2016). doi:10.1515/popets-2016-0021.
- [29] E. Mitchell, Y. Lee, A. Khazatsky, C. D. Manning, C. Finn, DetectGPT: Zero-shot machine-generated text detection using probability curvature, in: *Proc. ICML*, 2023. doi:10.48550/arXiv.2301.11305.
- [30] A. Pedrotti, M. Papucci, C. Ciccio, et al., Stress-testing machine generated text detection: Shifting language models writing style to fool detectors, in: *Findings of ACL*, 2025. doi:10.48550/arXiv.2505.24523.
- [31] Y. Gu, S. Li, X. Hu, MASH: Evading black-box AI-generated text detectors via style humanization, arXiv:2601.08564 (2026). doi:10.48550/arXiv.2601.08564.
- [32] H. Zhang, B. L. Edelman, D. Francati, et al., Watermarks in the sand: Impossibility of strong watermarking for generative models, in: *Proc. ICML*, 2024. doi:10.48550/arXiv.2311.04378.
- [33] J. Wu, S. Yang, R. Zhan, Y. Yuan, L. S. Chao, D. F. Wong, A survey on LLM-generated text detection: Necessity, methods, and future directions, *Computational Linguistics* 51 (2025). doi:10.1162/coli_a_00549.
- [34] E. Vyborov, O. Osypenko, S. Sotnyk, Exploring fact memorization and style imitation in LLMs using QLoRA, arXiv:2406.08582 (2024). doi:10.48550/arXiv.2406.08582.
- [35] W. Li, J. Liu, A. Liu, et al., BIG5-CHAT: Shaping LLM personalities through training on human-grounded data, arXiv:2410.16491 (2025). doi:10.48550/arXiv.2410.16491.
- [36] H. McGovern, R. Stureborg, Y. Suhara, D. Alikaniotis, Your large language models are leaving fingerprints, arXiv:2405.14057 (2024). doi:10.48550/arXiv.2405.14057.
- [37] O. Varol, E. Ferrara, C. A. Davis, F. Menczer, A. Flammini, Online human-bot interactions: Detection, estimation, and characterization, in: *Proc. ICWSM*, 2017. doi:10.1609/icws.v11i1.14871.
- [38] P. Piercey, R. Pearce, N. Veldt, Coordinated botnet detection in social networks via clustering analysis, in: *Proc. ACM HPC ’23 Workshop*, 2023. doi:10.1145/3605731.3608959.
- [39] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, QLoRA: Efficient finetuning of quantized LLMs, in: *Proc. NeurIPS*, 2023. doi:10.48550/arXiv.2305.14314.
- [40] I. Ariyaratne, et al., Behavior change as a signal for identifying social media manipulation, arXiv:2603.03128 (2026). doi:10.48550/arXiv.2603.03128.