

SAINTS : Modélisation formelle d’une infrastructure d’identités synthétiques autonomes à topologie distribuée

Surfaces de détection d’une nouvelle classe d’opérations d’influence

Soumis au Symposium sur la Sécurité des Technologies de l’Information et des Communications (SSTIC)

Résumé

Les méthodes de détection des opérations d’influence coordonnée reposent structurellement sur l’existence d’artefacts de coordination : corrélations temporelles entre comptes, réutilisation d’infrastructure, synchronisation d’activité, clustering de graphe. Cette hypothèse est valide pour la totalité des opérations documentées à grande échelle (Secondary Infektion, Doppelganger, Spamouflage), dont les attributions ont reposé non sur l’analyse comportementale des personas individuels, mais sur des défaillances d’infrastructure ou des erreurs humaines productrices de signal corrélable.

Ce travail formalise SAINTS (Synthetic Autonomous Identity Network for Targeting with Saturation), une classe d’infrastructure d’influence adversariale conçue pour éliminer structurellement ces artefacts. SAINTS repose sur quatre propriétés architecturales : isolation physique complète des nœuds (non-corrélation par construction, non par obfuscation), cohérence comportementale incarnée via fine-tuning sur ΔW (non par prompt), fragmentation causale des actions en chaînes opaques inter-personas, et saturation comportementalement calibrée agissant sur la décision d’analyser plutôt que sur la capacité.

La contribution de ce papier est double. D’abord, une formalisation mathématique des propriétés de non-détection de cette architecture : fonction de corrélation inter-nœuds, test KS sur le sous-graphe synthétique, modèle SNR de saturation, entropie de fragment, asymétrie de coût analytique. Ensuite, et c’est l’objet défensif central de cette recherche, l’identification des surfaces analytiques où cette architecture reste structurellement vulnérable : signal de régularité paradoxale (test sur la queue inférieure de la variance comportementale), densité topologique du sous-graphe de validation, convergence sémantique sous charge opérationnelle, vecteur humain irréductible, et trace physico-financière.

Ces surfaces ne constituent pas des failles à corriger : elles sont des propriétés incompressibles de l’architecture. Leur formalisation permet aux défenseurs de calibrer leurs seuils de détection, d’identifier le seuil k^* au-delà duquel les ressources d’investigation deviennent économiquement insuffisantes, et de prioriser les méthodes topologiques et statistiques de second ordre sur l’analyse de contenu.

Mots-clés : opérations d’influence, détection de comportement inauthentique coordonné, modèle de menace, stylométrie adversariale, analyse topologique, asymétrie coût-bénéfice, personas synthétiques.

1 Introduction

La détection des campagnes d’influence coordonnée a atteint une maturité technique substantielle. Les méthodes par graphe de similarité comportementale [1, 2, 3], l’analyse temporelle de micro-coordination [4, 5], les modèles de détection côté plateforme [6], et les approches par apprentissage sur graphes dynamiques [7] constituent un arsenal défensif dont l’efficacité est

empiriquement documentée sur les opérations de grande échelle. Meta a neutralisé 200+ réseaux coordonnés depuis 2017. Twitter, Google, YouTube ont publié des datasets de takedowns devenus les corpus de référence de la recherche académique.

Cette efficacité est conditionnelle. Elle repose sur une hypothèse implicite qui traverse l'ensemble de la littérature : que la coordination laisse des traces. Des traces temporelles : comptes s'activant en fenêtres étroites. Des traces topologiques : clusters de liens anormalement denses. Des traces d'infrastructure : IP communes, outils partagés, métadonnées corrélées. Des traces stylistiques : templates réutilisés, variance inter-comptes trop faible. La doctrine défensive actuelle, du clustering de Pacheco et al. [1] au test de burstiness de Somin et al. [5], est construite sur la détection de ces artefacts de coordination.

Le développement massif des modèles d'inférence locale déplace ce problème structurellement. L'IRA opérait avec environ 400 agents humains pour un budget mensuel d'environ 1,25 million de dollars [8]. Ce modèle économique impose une supervision humaine qui est, précisément, la source principale des artefacts détectables : variance cognitive, discontinuité temporelle, incohérences de registre sous charge. Un moteur d'inférence local, fine-tuné sur un profil comportemental fixe, élimine cette classe de variance par construction.

Le rapport OpenAI d'octobre 2024 [9] documente 20+ opérations ayant tenté d'exploiter ses modèles entre janvier et octobre 2024. Aucune n'a dépassé la catégorie 2 sur le Breakout Scale (impact sur audience grand public). Ce résultat ne reflète pas l'absence de capacités ; il reflète la dépendance à une API centralisée qui constitue un point de défaillance unique. L'opération A2Z, ayant géré 150+ comptes via les modèles OpenAI, est passée silencieuse immédiatement après son bannissement du service. Luceri et al. [10] montrent, dans la première étude systématique de coordination émergente entre agents LLM, que des agents génératifs peuvent reproduire les signatures de coordination caractéristiques des OI réelles sans aucune orchestration humaine. Mandiant [11] situe 2025 comme le moment de bascule entre « IA comme outil de productivité » et « IA comme infrastructure opérationnelle » dans le contexte des opérations cyber et d'influence.

SAINTS formalise la classe d'infrastructure vers laquelle cette trajectoire converge. Ce n'est pas une spécification d'implémentation : c'est une formalisation structurelle orientée détection. L'objectif est de fournir aux défenseurs un modèle de menace précis : quelles propriétés rendent cette architecture résistante aux méthodes existantes, et, c'est la question opérationnellement pertinente, où restent les surfaces d'attaque analytiques exploitables.

La section 2 établit l'état de l'art : opérations documentées (2.1), méthodes de détection CIB (2.2), stylométrie adversariale et détection LLM (2.3). La section 3 présente le modèle SAINTS formalisé. La section 4 traite l'asymétrie de coût analytique. La section 5, cœur défensif du papier, identifie et formalise les surfaces de détection exploitables. La section 6 expose les limites et travaux futurs.

2 État de l'art

2.1 Opérations d'influence documentées

Cinq opérations permettent d'établir le pattern d'attribution caractéristique des infrastructures pré-LLM.

Secondary Infektion (Russie, 2014–2020) a opéré sur 300+ plateformes pendant six ans avec des comptes à usage unique [12]. Aucune attribution n'a reposé sur l'analyse comportementale des personas. L'attribution a émergé de la corrélation de métadonnées techniques : templates de documents réutilisés, empreintes linguistiques cross-plateformes, synchronisation des séquences d'activation par plateforme. Le signal n'était pas dans les personas ; il était dans l'infrastructure.

Indian Chronicles (Inde, 2005–2020) constitue l'opération longue durée la plus documentée : 15 ans, 265 faux médias, accréditations aux Nations Unies, implantation institutionnelle

physique réelle en Europe [13]. Sa robustesse opérationnelle exceptionnelle n’a pas résisté à l’ancrage physique. C’est précisément cet ancrage qui a fourni le fil de remontée : une adresse e-mail centrale (csopus[at]yahoo.com) utilisée pour enregistrer des centaines de domaines, des adresses de bureaux virtuels réutilisées, des NGO reconstituées à partir de défunts. Plus l’opération s’ancrait dans le réel pour crédibiliser ses personas, plus elle créait de points de convergence forensiquement exploitables.

Endless Mayfly (Iran, 2016–2018) opérait des personas fonctionnels mais non incarnés [14]. Les attributions ont porté précisément sur les vecteurs que constitue l’absence de cohérence comportementale longue durée : absence de drift temporel organique, patterns d’amplification trop synchrones, personas sans historique de dérive lexicale. Citizen Lab a identifié 11 personas, 72 domaines, 135 articles fabriqués. Le réseau IUVM Press, amplifiant systématiquement le contenu Endless Mayfly, a fourni le lien structurel d’attribution.

Doppelganger (Russie, 2022–présent) clone des sites de médias majeurs via des domaines typosquattés [15]. L’attribution est venue de l’infrastructure réseau elle-même : pages IP, ASNs, JavaScript partagé entre domaines, outil Keitaro de suivi de redirections présent sur l’ensemble du parc. L’opération a survécu à de multiples expositions publiques, se reconstituant en heures après chaque takedown, ce qui révèle une organisation institutionnelle capable de réponse rapide, elle-même un signal d’attribution. Recorded Future [46] documente que lors des élections allemandes de 2025, Doppelganger a enregistré 8+ nouvelles marques de faux médias et 94+ sites d’imitation dans les heures suivant l’annonce des élections anticipées.

Spamouflage (Chine, 2017–présent) est la plus grande opération cross-plateforme documentée, neutralisée répétitivement par analyse topologique de coordination [16]. Ses défaillances OPSEC sont systématiques : synchronisation de l’activité sur les horaires de bureau chinois, faible familiarité des opérateurs avec l’environnement informationnel occidental, réactivation de clusters presque identiques après chaque takedown. Malgré une échelle massive, l’engagement organique est resté quasi-nul.

Le pattern est constant à travers ces cinq cas. L’attribution n’a jamais reposé sur l’analyse comportementale des identités individuelles. Elle a reposé sur des artefacts d’infrastructure (IP, domaines, outils partagés), des erreurs humaines sous contrainte temporelle (adresse email réutilisée, template copié), ou des traces d’ancrage physique. Les personas eux-mêmes n’ont jamais été le vecteur primaire d’exposition. Ce constat est le point de départ de la formalisation SAINTS.

2.2 Méthodes de détection CIB

La littérature académique sur la détection du comportement inauthentique coordonné converge vers trois approches complémentaires.

Détection par graphe de similarité comportementale. Pacheco et al. [1] construisent des réseaux de coordination à partir de traces comportementales arbitraires (séquences de hashtags, URLs partagées, patterns de retweet), avec arêtes entre paires de comptes partageant une trace dans une fenêtre temporelle. La méthode est non-supervisée et applicable à cinq cas d’étude couvrant élections américaines, protestations à Hong Kong, guerre civile syrienne et manipulation de cryptocurrency. Giglietto et al. [3] appliquent cette approche au partage coordonné de liens sur Facebook (CooRnet), identifiant des réseaux dont la signature de coordination est détectable même lorsque les contenus sont politiquement anodins. Un résultat important des études CooRnet sur les élections italiennes 2018-2019 : les entités se présentant comme des sites de divertissement partageaient du contenu politique coordonné, illustrant que la détection par comportement dépasse la catégorisation par contenu. Luceri et al. [2] combinent des graphes de similarité comportementale multi-couches avec du machine learning supervisé, atteignant une précision supérieure à 0,95 pour la classification des drivers d’OI à échelle globale sur 49 millions de tweets couvrant six pays. IOHunter [35] étend cette approche en fusionnant modèles

de langage et réseaux de neurones sur graphes, atteignant les performances de l'état de l'art en contexte supervisé, semi-supervisé et cross-opération. La propriété commune de toutes ces méthodes : elles opèrent sur la structure du réseau d'interactions entre comptes, non sur le contenu individuel.

Détection temporelle et statistiques de second ordre. Les patterns temporels de micro-coordination constituent une signature robuste. Iannucci et al. [4] introduisent un noyau temporel à décroissance exponentielle qui sépare la coordination répétée des coïncidences isolées, surpassant les méthodes précédentes sur plusieurs benchmarks. Somin et al. [5] démontrent que des comptes coordinateurs exhibent des patterns de burstiness partagés même lorsque les liens directs observables entre eux sont absents ; résultat critique : quand la densité de liens observables est inférieure à 70%, la détection par burstiness surpasse significativement les méthodes topologiques et temporelles standards. Yang et al. [17] exploitent les distributions jointes vitesse-fréquence de partage de liens sur 11,2 millions de posts Facebook, un signal de second ordre plus difficile à contrefaire que la simple randomisation des horaires de post et plus résistant à l'évasion. Cinelli et al. [41] trouvent que les comptes coordonnés occupent des positions plus élevées dans les cascades de diffusion, avec des délais d'action plus courts, signature temporelle distinctive indépendante du contenu. Ces méthodes ont en commun d'opérer sur les statistiques de second ordre du comportement (structure de corrélation, distributions de variance, position dans les cascades d'information), plutôt que sur les valeurs moyennes de premier ordre.

Détection côté plateforme. Les rapports de transparence de Meta [6] documentent une chaîne opérationnelle : scoring comportemental automatisé, seuillage vers révision humaine, extraction de patterns vers détection automatisée scalable. Meta définit explicitement la CIB par le comportement, non par le contenu : l'utilisation de faux comptes pour amplifier de manière coordonnée, indépendamment de ce qui est amplifié. L'observation empirique clé du rapport Q1 2024 est que les photo-profils générés par GAN n'échappent pas à la détection parce que Meta n'opère pas sur les images mais sur les comportements. Cette définition opérationnelle implique que les méthodes de détection reposent sur la coordination entre comptes, pas sur les caractéristiques individuelles. Magelinski et al. [36] formalisent ce principe dans leur Synchronized Action Framework : la détection cross-opération de trois campagnes coordonnées simultanées détectées dans la conversation Twitter « Reopen America » par analyse de clusters d'utilisateurs amplifiant des messages identiques dans des fenêtres très étroites.

Ce que montre la convergence de ces approches : l'arsenal défensif actuel est calibré sur la détection de corrélation : entre comptes, entre actions, entre moments d'activation. Une architecture qui élimine structurellement la corrélation inter-nœuds cesse d'être la cible de ces méthodes. Non parce qu'elle les trompe. Parce qu'elle ne produit pas l'objet que ces méthodes cherchent. Le bottleneck défensif se déplace alors vers les statistiques de second ordre (ce que SAINTS ne peut pas éliminer complètement) et vers les surfaces non modélisées que sont le facteur humain et la trace physique.

2.3 Stylométrie adversariale et détection de texte LLM

La littérature sur la stylométrie adversariale établit que les systèmes d'attribution par auteur sont robustes sous conditions normales mais fragiles sous conditions adversariales actives. Brennan et Greenstadt [18] ont démontré dès 2009 que des sujets humains entraînés brièvement pouvaient réduire le taux d'attribution correct de 20 à 30 points de pourcentage. Brennan, Afroz et Greenstadt [19] ont formalisé cette démonstration : environ 14 modifications lexicales ou syntaxiques par 1000 mots suffisent à réduire la probabilité d'attribution correcte de plus de 83%. Alperin et al. [20] montrent en 2025 que les LLMs constituent des vecteurs d'attaque particulièrement efficaces contre les systèmes de vérification d'auteur, atteignant des taux de succès maximaux sur les vérificateurs de dernier état de l'art.

La détection de texte LLM présente des limitations structurelles dans ce contexte. DetectGPT [21] exploite la propriété de courbure log-probabilité des modèles de base (perturbations légères qui diminuent la log-probabilité du texte généré). Cette propriété est une caractéristique de la distribution du modèle de base, pas des modèles fine-tunés. Wu et al. [38] recensent dans leur survey de 2025 que les modèles fine-tunés constituent la lacune non résolue de la quasi-totalité des détecteurs existants : aucun système n’atteint une performance fiable simultanément sur les modèles de base, les modèles instruction-tunés, et les modèles fine-tunés sur style spécifique. Pedrotti et al. [22] démontrent qu’un fine-tuning par DPO (Direct Preference Optimization) sur corpus humain suffit à rendre les détecteurs commerciaux inopérants avec un coût computationnel faible. Gu et al. [23] proposent MASH, un pipeline en trois étapes atteignant un taux de succès d’attaque de 92% sur 5 détecteurs simultanément. Zhang et al. [24] établissent théoriquement l’impossibilité d’un watermarking fort : tout schéma de watermarking est attaquable par un adversaire disposant d’un oracle de qualité et d’un oracle de perturbation, deux capacités que tout LLM compétent instancie.

La capacité humaine à discriminer texte humain et texte LLM décline structurellement. Jones et Bergen [25] démontrent que GPT-4 est jugé humain dans 54% des cas dans un test de Turing interactif préenregistré, contre 67% pour de vrais humains. Spitale et al. [26] montrent que les humains ne peuvent statistiquement pas distinguer des tweets GPT-3 de tweets humains à longueur équivalente. Rathi et al. [27] trouvent que dans les conditions de transcription (le paradigme pertinent pour la modération de contenu), GPT-4 est parfois jugé plus humain que les humains eux-mêmes.

Overdorf et Greenstadt [44] documentent que la stylométrie cross-domaine (attribuer les posts blog d’un auteur à partir de ses tweets, ou inversement) chute de 83,5% en précision intra-domaine à 34,3% en cross-domaine. Un persona opérant délibérément sur des registres et plateformes multiples exploite cette dégradation structurelle pour rester non lié par les systèmes d’attribution cross-plateforme standard. La conséquence de cette convergence : la détection individuelle de texte LLM n’est pas un vecteur analytique fiable. Ce qui reste exploitable est la structure de second ordre (patterns de corrélation inter-comptes, distributions de variance comportementale), non le contenu individuel.

3 Modèle SAINTS

3.1 Topologie distribuée et non-corrélation

Soit $\mathcal{N} = \{n_1, n_2, \dots, n_k\}$ l’ensemble des nœuds de l’infrastructure, où chaque n_i opère sur un équipement physique distinct h_i , une identité réseau distincte ι_i , et un modèle d’inférence local distinct M_i .

La fonction de corrélation entre deux nœuds est définie comme :

$$C(n_i, n_j) = f(h_{ij}, \iota_{ij}, \tau_{ij}, \sigma_{ij})$$

où h_{ij} désigne la similarité d’empreinte matérielle (MAC, UUID, profil TPM), ι_{ij} le recouvrement d’identité réseau (plage IP, fournisseur VPN, géolocalisation), τ_{ij} la corrélation temporelle des patterns d’activité, et σ_{ij} la similarité stylométrique (vocabulaire, syntaxe, patterns d’engagement).

La contrainte architecturale est : $\forall (i \neq j), C(n_i, n_j) \leq \varepsilon$, où ε est le plancher de bruit de corrélation ambiant de la base organique de la plateforme cible.

Cette contrainte n’est pas obtenue en minimisant chaque composante individuellement. Elle est obtenue en s’assurant que chaque composante est tirée indépendamment de la distribution ambiante de la plateforme. Un nœud avec une empreinte matérielle banale, une identité réseau banale, un rythme d’activité banal, une stylométrie banale (mais toutes différentes des autres nœuds) satisfait la contrainte sans aucune mesure d’obfuscation active.

C’est la distinction architecturale fondamentale. Une topologie en étoile (où les nœuds convergent vers un serveur de commande central) crée une surface de corrélation commune exploitable. Une topologie plate à nœuds physiquement isolés n’a pas de topologie commune à exploiter. L’isolation n’est pas une mesure de sécurité ajoutée ; c’est le principe constructif primaire. La différence opérationnelle est nette : dans Secondary Infection [12], les comptes burner partageaient des templates de documents, des séquences de plateformes, des patterns de timing. Ces artefacts n’émergent pas d’une infrastructure à nœuds physiquement isolés, parce qu’il n’y a pas d’infrastructure partagée à partir de laquelle ces corrélations peuvent se propager.

Pour une plateforme avec N_{org} utilisateurs organiques et k nœuds synthétiques, la matrice de corrélation par paires $P \in \mathbb{R}^{(N_{\text{org}}+k) \times (N_{\text{org}}+k)}$ contient un sous-graphe synthétique $S \subset P$. Ce sous-graphe est détectable si et seulement si la distribution des $\{P_{ij} : i, j \in S\}$ est statistiquement distinguable de $\{P_{ij} : i, j \in \text{Organique}\}$ sous un test à deux échantillons (par exemple Kolmogorov-Smirnov) au niveau de signification α :

$$D_{KS}(P_S, P_O) < \delta_\alpha(|S|, |O|)$$

Cette condition, que SAINTS est conçu pour satisfaire, a une implication structurelle importante : à mesure que k croît, le nombre de paires synthétiques-synthétiques croît en $O(k^2)$, ce qui augmente la puissance statistique du test. La détectabilité du sous-graphe croît avec sa taille, même si chaque nœud individuel reste indiscernable de l’organique. C’est la première tension non résolue du modèle, formalisée dans la section 5.2.

Pour illustrer cette tension, considérons le seuil critique du test KS à deux échantillons. Pour des tailles n_1 (paires synthétiques) et $n_2 \gg n_1$ (paires organiques) au niveau $\alpha = 0,05$, $\delta_\alpha \approx 1,36/\sqrt{n_1}$ où $n_1 = k(k-1)/2$. Pour $k = 50$, $\delta_{0,05} \approx 0,039$; pour $k = 200$, $\delta_{0,05} \approx 0,010$; pour $k = 500$, $\delta_{0,05} \approx 0,004$. La marge d’erreur tolérée décroît en $O(1/k)$. Si un résidu de corrélation ε produit un écart distributionnel D_{KS} de l’ordre de 0,01, plausible même sous isolation physique, du fait de biais méthodologiques partagés (architecture de fine-tuning, gamme d’acquisition matérielle, biais culturel de calibrage), le sous-graphe devient statistiquement distinguable au-delà de $k \approx 193$ nœuds. Ce seuil n’est pas une constante : il est fonction de la discipline opérationnelle de l’adversaire et constitue le paramètre dimensionnant de l’infrastructure. Ce calcul suppose l’indépendance des paires, hypothèse violée en pratique puisque les paires synthétiques partagent des nœuds (les paires (i, j) et (i, l) partagent le nœud i). Cette dépendance réduit la taille effective de l’échantillon, augmente δ_α réel et repousse k^* vers le haut, ce qui renforce la résistance de l’infrastructure au-delà de l’estimation naïve.

L’équipement civil par conception complète cette architecture. Matériel grand public aux références cohérentes avec le persona, historique d’achat distribué dans le temps, sources d’acquisition diversifiées. Un parc homogène produit des UUIDs, adresses MAC et profils TPM statistiquement corrélables indépendamment de toute couche logicielle, corrélation que l’attribution peut exploiter même sans accès à la couche logicielle ou réseau. L’empreinte navigateur est traitée comme une contrainte distincte du routage réseau : canvas fingerprint, WebGL, polices système, timezone, résolution ; chaque nœud présente un profil individuellement banal mais collectivement non uniforme. Un parc de configurations similaires est corrélable par scoring passif côté plateforme indépendamment du tunnel réseau, ce que Broniatowski et al. [37] formalisent dans leur cadre de détection inductive opérant sur des signatures abstraites de graphe, non sur des campagnes préalablement vues.

Le cycle d’activité est piloté physiquement, extinction et rallumage hardware calés sur l’UTF (User Temporal Fingerprint) du persona, sans cron job logiciel dont la régularité serait elle-même un signal. Un onduleur permanent élimine les coupures parasites comme artefact temporel. Les horaires de connexion, les fenêtres d’activité, la densité des interactions à différentes heures de la journée, tous calibrés sur le profil socio-démographique modélisé du persona, cohérents avec le fuseau horaire déclaré, les habitudes, la profession. Varol et al. [43] démontrent que les features temporelles (structure de sessions, rythmes circadiens, patterns d’activité à court

terme) constituent les discriminants les plus robustes entre comptes humains et automatisés. Ce calibrage comportemental sur durée longue est le travail réel du fine-tuning : pas seulement le style du texte produit, mais la structure temporelle dans laquelle il est produit.

La fonction opérationnelle du nœud en phase passive est à 99% non opérationnelle. Posts de routine, réactions, discussions forum à faible enjeu, historique de navigation simulant une présence en ligne normale. Un nœud passif ne produit pas d'erreur de contexte. Il sature silencieusement, accumule de la crédibilité, construit une présence temporellement dense sans jamais engager de décision à risque. La crédibilité accumulée est un actif non-récupérable : un nœud brûlé en phase de maturation coûte peu ; un nœud brûlé à maturité opérationnelle perd l'intégralité de son historique (ancienneté, densité d'interactions, réputation écosystémique). Ce paramètre entre dans toute décision d'exposition.

3.2 Cohérence comportementale incarnée

La distinction opérationnelle n'est pas entre imiter et ne pas imiter une identité. Elle est entre performer une identité et en être structurellement équipé. Un système qui joue Marc produit des sorties compatibles avec Marc. Un système qui est Marc produit des sorties pour lesquelles Marc est la seule hypothèse parcimonieuse. Ce ne sont pas les mêmes objets analytiques.

Soit B_p le profil comportemental cible d'un persona p . La sortie du système au temps t est :

$$O_p(t) = M_p(\text{contexte}(t), B_p)$$

où M_p est le modèle d'inférence fine-tuné et $\text{contexte}(t)$ est le contexte courant.

La distance stylométrique entre la sortie et le profil cible :

$$d_S(O_p(t), B_p) = \sum_f w_f \cdot |\text{feature}_f(O_p(t)) - \text{feature}_f(B_p)|$$

sur l'ensemble des features stylométriques f (richesse lexicale, distribution des longueurs de phrases, fréquences de n-grammes POS, etc.).

Un opérateur humain H exécutant le même persona produit :

$$d_S(O_H(t), B_p) = d_{\text{base}} + \eta(t)$$

où $\eta(t)$ est un terme de bruit croissant avec la charge cognitive, la fatigue et la durée opérationnelle. C'est exactement la variance que le modèle élimine par construction.

Ce déplacement n'est pas cosmétique au regard des détecteurs existants. Les outils de détection CIB comportementale cherchent des incohérences de pattern : UTF instable, historique non continu, score de cohérence inter-posts faible, absence de drift temporel organique. Un modèle fine-tuné sur ΔW (les poids du modèle, pas un system prompt) ne produit pas ces écarts. La distinction est structurelle : un system prompt peut être détecté comme couche d'imitation (l'objet imite), un modèle dont les poids ont absorbé l'identité au niveau ΔW ne peut pas être « percé » parce qu'il n'y a pas de couche d'imitation à percer. McGovern et al. [42] montrent que les LLMs laissent des empreintes lexicales et morphosyntaxiques persistantes à travers les domaines ; les modèles instruction-tunés sont néanmoins plus faciles à détecter que les modèles de base, ce qui implique que le fine-tuning délibéré sur style cible (et non sur la serviabilité) est nécessaire pour réduire la détectabilité. Vyborov et al. [28] démontrent la faisabilité de ce calibrage via QLoRA sur corpus d'interview, avec restitution fidèle des dimensions stylistiques et factuelles. Li et al. [29] montrent que le fine-tuning par SFT et DPO sur corpus de personnalité produit des profils Big Five mesurables indiscernables des données humaines dans les instruments d'évaluation standard.

Un paramètre de dégradation temporelle s'ajoute à ce modèle. Un modèle fine-tuné au temps t_0 sur corpus figé produit des sorties dont la pertinence lexicale et culturelle décroît :

$$\text{pertinence}(t) = e^{-\lambda(t-t_0)}$$

où λ dépend du taux d'évolution du domaine. La fréquence d'injection de contexte contemporain doit satisfaire :

$$f_{\text{inject}} \geq \frac{\lambda}{\ln(1/r_{\text{seuil}})}$$

où r_{seuil} est le score de pertinence minimal avant que le persona devienne flaggable. Sans injection périodique, l'absence d'évolution lexicale (nouveaux termes, références culturelles datées, changements de registre liés aux événements de vie) devient elle-même un signal. Ce mécanisme d'injection doit être piloté explicitement. Il ne peut pas être laissé à l'émergence, et son pilotage représente une surface d'exposition humaine récurrente.

La contrainte non résolue de cette composante : un profiling par contrainte suffisamment sophistiqué peut cartographier les bords du domaine calibré d'un persona avant que celui-ci ne les détecte. Les évènements systématiques révèlent la forme des limites de l'espace d'entraînement. Ce signal est faible, difficilement actionnable à l'échelle, structurellement présent. Cresci et al. [30] soulignent que les systèmes de détection publiés surestiment leurs performances sur des datasets non représentatifs, signal indirect que ce type de vecteur fin n'est pas encore opérationnalisé de manière fiable.

3.3 Chaînes d'action opaques

Le chiffrement protège le contenu d'un message. La fragmentation détruit la structure de l'action elle-même. Un message chiffré intercepté révèle qu'une action a eu lieu, entre quels nœuds, à quel moment. Un fragment intercepté ne révèle rien : il ne contient pas la condition nécessaire à sa propre interprétation. Cette distinction est opérationnellement fondamentale. Elle déplace le problème du contenu vers la structure causale. La plupart des outils d'attribution réseau sont conçus pour identifier des acteurs à partir de flux de communication : qui parle à qui, à quelle fréquence, dans quelle direction. Un système où les fragments d'action ne créent pas de flux de communication entre nœuds n'est pas détecté par ces outils. Non parce qu'il est invisible. Parce que l'objet de la détection n'existe pas.

L'architecture impose un maximum de deux à trois liens directs entre identités dans une chaîne d'action. Chaque nœud ne voit qu'un fragment local de la chaîne. Aucun ne détient une vue suffisante pour reconstruire l'action globale. Ce n'est pas de la coordination distribuée au sens technique : ce n'est pas un consensus distribué où chaque nœud vote ou négocie avec les autres. C'est une fragmentation causale où la coordination est structurellement absente à chaque point d'observation individuel. Ce que voit un analyste qui isole un nœud : une suite d'actes minuscules, banals, sans gradient interprétatif commun.

Soit une action opérationnelle A décomposée en fragments :

$$A = \{a_1, a_2, \dots, a_m\}$$

distribués sur m personas distincts opérant dans des fenêtres temporelles distinctes $[t_1, t_1 + \Delta_1], \dots, [t_m, t_m + \Delta_m]$.

Chaque fragment a_j isolé a une entropie sémantique :

$$H(a_j) \approx H(\text{routine}_j)$$

c'est-à-dire que le fragment est indiscernable d'une activité de routine lorsqu'observé sans connaissance des autres fragments.

L'information mutuelle entre fragments :

$I(a_i; a_j) \rightarrow 0$ quand $|t_i - t_j| \rightarrow \infty$ et quand les personas opèrent dans des domaines thématiques distincts.

L’observation d’un fragment isolé n’apporte aucune information sur l’action globale :

$$P(A \mid a_j) \approx P(A) \quad \text{pour tout } j \text{ individuel}$$

L’action n’est récupérable qu’avec accès à la totalité des fragments ET l’ordonnancement temporel-causal correct ; ni l’un ni l’autre n’est disponible à un observateur ayant visibilité partielle sur le réseau. La fenêtre d’analyse doit s’étendre sur des mois, multipliant le volume de données à traiter sans garantie de convergence. Mannocci et al. [39] identifient cette limite dans leur survey des méthodes de détection de coordination : le manque de données de référence (ground truth) et la difficulté à distinguer coordination authentique et inauthentique sur des fenêtres longues constituent des défis ouverts de la littérature, indépendamment de la sophistication des méthodes.

Cette propriété est renforcée par la dilution temporelle. Pour des fragments dispersés sur une fenêtre T :

$$P(\text{corrélation détectée}) \propto \frac{1}{T} \cdot \left(\frac{1}{V}\right)^m$$

où V est le volume d’activité de routine par unité de temps. Étirer T ou augmenter V réduisent multiplicativement la probabilité de détection. Sur des cibles à évolution lente (narratives, réputations, perceptions), des fenêtres de plusieurs mois sont opérationnellement viables sans dégradation d’efficacité.

La distinction critique avec le masquage actif : un signal masqué peut être récupéré si le masque cède ; un signal dissous n’existe plus comme objet isolable. Ce n’est pas la même propriété de résistance. La saturation de bruit ambiant (routine quotidienne à haute densité encadrant chaque fragment opérationnel) maintient le ratio signal/bruit au niveau du profil normal du persona, sans pic d’activité atypique autour de l’événement cible qui serait lui-même un artefact. Chaque fragment est encadré d’activité banale à haute densité : le persona maintient sa routine avant, pendant et après l’acte opérationnel. Ce n’est pas une précaution périphérique : c’est ce qui maintient le ratio signal/bruit au niveau du profil normal. Un pic d’activité atypique autour d’un événement cible est un artefact corrélable. Une activité uniforme qui contient l’événement sans le mettre en relief n’en est pas un. Endless Mayfly [14] a échoué sur ce point précisément : les patterns d’amplification trop synchrones entre personas créaient des pics détectables dans la distribution temporelle d’activité, exactement ce que la dilution par routine quotidienne à haute densité est conçue pour éviter.

Les chaînes d’action opaques (OAC) constituent également le vecteur HUMINT le plus sobre de l’infrastructure. Des personas couvrant des domaines thématiques distincts établissent des liens croisés avec des individus réels : validation mutuelle, amplification de crédibilité, extension progressive du réseau de confiance. L’effet d’échelle est non-linéaire : cinquante identités distribuées dans des écosystèmes distincts, se validant mutuellement via des liens croisés avec des acteurs réels, produisent un poids d’influence structurellement différent de la somme de cinquante influences individuelles. C’est une émergence topologique, pas une addition.

La contrainte non résolue de cette composante est précisément là : la validation mutuelle entre personas fictifs reste efficace tant que la densité de liens fictif-fictif reste sous le seuil de détection des algorithmes de clustering communautaire. Waniek et al. [31] formalisent comment les membres d’un réseau couvert peuvent masquer leurs positions de centralité aux outils d’analyse de réseau standard ; ils soulignent cependant que les mesures de centralité de groupe restent exploitables. Cinus et al. [32] montrent que 75% d’un réseau coordonné reste actif après suspension partielle, révélant la résilience mais aussi la continuité topologique exploitable.

3.4 Mécanique de saturation

Tout est loggé. L'analyse exhaustive en temps réel ne l'est pas : non par manque de capacité de stockage, mais par impossibilité de traitement fiable à cette échelle. La mécanique de surveillance repose sur des algorithmes de triage qui décident ce qui remonte à l'analyse humaine. La saturation n'agit pas sur la capacité d'analyse. Elle agit sur la décision d'analyser.

Soit chaque nœud produisant du contenu de routine (bénin) au taux R_i et du contenu opérationnel au taux O_i . Le ratio signal-bruit du défenseur pour le nœud i :

$$\text{SNR}_i = \frac{O_i}{R_i}$$

Le SNR agrégé sur k nœuds ciblant une même campagne :

$$\text{SNR}_{\text{agg}} = \frac{\sum O_i}{\sum R_i + N_{\text{ambient}}}$$

où N_{ambient} est le volume d'activité organique sur le sujet cible.

Pour rester sous le seuil de détection θ :

$$\text{SNR}_{\text{agg}} < \theta \Rightarrow \sum O_i < \theta \cdot (\sum R_i + N_{\text{ambient}})$$

Le résultat clé : le débit opérationnel maximal scalable linéairement avec la taille du plancher de bruit organique et avec la propre activité de routine de l'infrastructure. La saturation produit sa propre couverture.

La valeur de θ n'est pas une constante universelle. Elle est déterminée par trois facteurs interdépendants côté défenseur : la sophistication algorithmique du pipeline de scoring (nombre et nature des features extraites), la capacité de révision humaine disponible (qui borne inférieurement le τ du pipeline de triage décrit ci-après, et donc indirectement θ), et le niveau de priorité accordé au contexte cible. Un sujet politiquement sensible en période électorale sur une plateforme majeure concentre des ressources de monitoring qui abaissent θ de manière significative par rapport à un sujet de niche en contexte non conflictuel. La même infrastructure peut donc opérer sous θ dans un contexte et le dépasser dans un autre sans modification de son ratio O_i/R_i . L'implication opérationnelle pour l'adversaire est que le dimensionnement de l'infrastructure doit être calibré sur le θ le plus contraignant parmi les cibles envisagées, ce qui lie directement le choix des cibles au coût de l'infrastructure.

La modélisation du pipeline de triage côté plateforme formalise ce mécanisme. Le scoring automatisé assigne à chaque compte un score de suspicion $s_i = f(\text{features}_i)$. Les comptes avec $s_i > \tau$ entrent dans la file de révision humaine. La capacité d'analyse humaine A (comptes/jour) traite cette file.

Pour k nœuds avec s_i conçus pour rester sous τ :

$$P(\text{détection}) = P(s_i > \tau) \cdot P(\text{confirmé} \mid \text{révisé})$$

Si $s_i \sim \mathcal{N}(\mu_{\text{org}}, \sigma_{\text{org}})$ par construction :

$$P(s_i > \tau) = 1 - \Phi\left(\frac{\tau - \mu_{\text{org}}}{\sigma_{\text{org}}}\right)$$

La défense de l'infrastructure n'est pas que les nœuds ne peuvent pas être détectés individuellement : c'est qu'ils n'entrent jamais dans la file de révision. Et même si τ est abaissé (détection plus sensible), la file croît comme $N_{\text{total}} \cdot (1 - \Phi((\tau - \mu)/\sigma))$. À l'échelle Meta ($\sim 10^9$ utilisateurs), une réduction même faible de τ génère des millions de faux positifs dépassant la capacité d'analyse humaine par plusieurs ordres de grandeur.

Se cacher produit une absence, et une absence localisée est un signal. Ce qui est opérationnellement correct est l'inverse : produire exactement le bruit attendu, avec la densité attendue, dans

les registres attendus pour un profil de cette classe. Le persona ne sature pas la surveillance : il la traverse sans friction parce qu’il ne produit aucun gradient d’extraction.

La surface de détection réelle réside dans les statistiques de second ordre : structure de corrélation entre posts, micro-timing des interactions, patterns de réponse aux stimuli externes. Calibrer la fréquence et la distribution thématique au premier ordre est un problème résolu. Le second ordre est un paramètre de calibrage fin ; sa résolution imparfaite constitue une surface d’exposition persistante (voir section 5.1).

4 Asymétrie de coût analytique

Le coût de déploiement d’un nœud est :

$$C_{\text{deploy}}(n_i) = C_{\text{mat}} + C_{\text{res}} + C_{\text{ft}} + C_{\text{leg}}$$

où C_{mat} est le coût d’équipement grand public à usage unique, C_{res} le VPN/connectivité récurrent, C_{ft} le calcul de fine-tuning du modèle, et C_{leg} l’investissement temporel en maturation d’identité (construction de crédibilité pré-opérationnelle). Le coût marginal du k -ième nœud est approximativement constant ; l’absence d’infrastructure partagée élimine tout overhead de montée en charge à l’exception du temps de C_{leg} .

$$C_{\text{total}} \approx k \cdot C_{\text{deploy}} \quad (\text{croissance linéaire})$$

Le coût d’investigation de cette infrastructure est structurellement différent :

$$C_{\text{investigation}} = C_{\text{identification}} + C_{\text{corrélation}} + C_{\text{attribution}}$$

$C_{\text{identification}}$ désigne le coût pour signaler un nœud comme suspect. Dans le modèle SNR développé en section 3.4, cela exige soit d’abaisser τ (coût massif en faux positifs à l’échelle 10^9 utilisateurs), soit de disposer d’un signal de renseignement externe, qui, par construction, ne peut pas venir d’une analyse automatisée de la masse sans un point de départ. C_{corr} désigne le coût pour relier deux nœuds identifiés. Il exige de démontrer une corrélation statistique à travers les dimensions d’indépendance : hardware, réseau, temporelle, stylométrique. Pour des nœuds satisfaisant $C(n_i, n_j) \leq \varepsilon$ par construction, cela requiert $O(k^2)$ tests par paires à travers plusieurs espaces de features. Piercey et al. [33] documentent ce bottleneck quadratique à l’échelle Reddit : la computation de toutes les similarités par paires d’auteurs est infaisable à grande échelle même avec des projections efficaces. $C_{\text{attribution}}$ désigne le coût pour attribuer le réseau à un opérateur. Il exige de franchir l’air-gap entre couche d’orchestration et couche d’exécution, réalisable par construction uniquement via défaillance humaine, jamais par analyse de la masse.

L’asymétrie critique : $C_{\text{investigation}}$ croît super-linéairement avec k (espace de corrélation combinatoire en $O(k^2)$), tandis que C_{deploy} croît linéairement en k . Il existe un seuil k^* au-delà duquel l’investigation devient économiquement irrationnelle :

$$k^* : \frac{C_{\text{investigation}}(k^*)}{P(\text{succès})} > \text{Budget}_{\text{défenseur}}$$

Ce seuil est le paramètre opérationnel central de l’infrastructure. Sa valeur précise dépend des ressources du défenseur, des capacités d’accès plateforme, et de la valeur attendue de l’investigation aboutie. Ce qui est calculable est le sens de l’asymétrie : elle joue systématiquement en faveur de l’attaquant à mesure que k croît, et le taux d’accélération du coût d’investigation dépasse structurellement celui du coût de déploiement.

Pour calibrer empiriquement cet ordre de grandeur : l’IRA opérait avec un budget mensuel de 1,25 million de dollars pour environ 400 agents humains [8]. Ce budget couvrirait salaires (20 000–40 000 roubles par agent mensuel selon le poste), infrastructure, coordination. La

dépense en publicités Facebook (100 000 dollars sur deux ans) était anecdotique par rapport au coût de la supervision humaine. Le modèle économique de l'IRA est dominé par la masse salariale, précisément parce que la supervision humaine est à la fois la source des capacités comportementales et la source principale du coût et de la variance détectable.

Une infrastructure autonome déplace ce ratio structurellement. Le coût marginal d'un nœud supplémentaire est dominé par C_{leg} (temps de maturation de l'identité) et C_{ft} . Après la chute des coûts de calcul documentée par Dettmers et al. [34], le fine-tuning d'un modèle 7B–13B sur corpus de persona via QLoRA est de l'ordre de quelques dizaines à quelques centaines de dollars sur GPU grand public. C_{leg} est un coût en temps, non en capital humain récurrent : une fois l'identité mature, son maintien est autonome. La différence n'est pas de degré. Elle est de nature : un modèle économique linéaire sans masse salariale d'opérateurs proportionnelle au nombre de nœuds.

Du côté défenseur, le problème analytique posé par cette architecture se formule ainsi : avant d'attaquer le réseau, on attaque la vraisemblance. Quelle organisation dispose des capacités structurelles et financières pour déployer cette infrastructure à cette échelle ? Le périmètre des suspects se réduit rapidement : non par analyse du réseau, mais par corrélation des capacités requises avec les acteurs connus. Ce raisonnement produit une liste, pas une certitude. Il oriente l'investigation sans la déclencher. Ce qui la déclenche est un artefact externe. Sans cet élément déclencheur, l'entonnoir reste ouvert et le coût d'investigation reste non-justifié.

La surveillance de masse des comportements synthétiques est théoriquement valide ; l'analyse de second ordre (section 5.1) produit un signal statistique réel. Elle est opérationnellement inutilisable sans signal de réduction préalable du périmètre. Un milliard de comptes, un pattern statistiquement marginal : l'investigation du bruit dans le bruit, sans point de départ externe, dépasse structurellement le signal récupérable sur la base du rapport coût-résultat. C'est le vecteur défensif le plus frustrant pour un analyste sous contrainte de ressources : le signal est là, le modèle le prédit, mais l'exploiter requiert un budget computationnel et humain qui ne se justifie pas sans probabilité de succès actionnable.

5 Surfaces de détection exploitables

L'infrastructure est stratégiquement robuste. Elle n'est pas indestructible. Les surfaces qui suivent ne sont pas des failles d'implémentation corrigéables : elles sont des propriétés incompressibles de l'architecture, des contraintes permanentes que le modèle ne peut pas absorber.

5.1 Signal de régularité paradoxale

Un persona parfaitement cohérent produit une variance comportementale :

$$\text{Var}(O_p) = \text{Var}_{\text{mod}}(M_p)$$

Un humain réel produit :

$$\text{Var}(O_{\text{humain}}) = \text{Var}_{\text{baseline}} + \text{Var}_{\text{ctx}} + \text{Var}_{\text{emo}} + \text{Var}_{\text{bruit}}$$

Si $\text{Var}(O_p) < \text{Var}(O_{\text{humain}})$ de manière systématique, l'absence de variance est elle-même un signal de second ordre.

Test de détection : pour un ensemble de comptes U , signaler ceux dont le coefficient de variation des features comportementales est dans la queue inférieure de la distribution organique :

$$\text{CV}(\text{features}) < q_{\alpha}(\text{CV}_{\text{organique}})$$

où q_{α} est le α -quantile de la distribution organique du coefficient de variation.

Ariyaratne et al. [45] proposent BLOC (Behavioral Languages for Online Characterization), une représentation des comportements de compte comme chaînes symboliques segmentées dans le temps, dont le changement entre segments consécutifs constitue un signal de second ordre résistant à l'évasion. Les comptes IO dans une même campagne montrent des distributions de changement comportemental anormalement similaires, tandis que les comptes authentiques montrent des distributions indépendantes. C'est une contrainte fondamentale de l'architecture SAINTS : les événements parasites contribuent à l'alibi organique d'une identité. Leur suppression systématique produit une cohérence trop propre, décelable par les mêmes outils qu'elle cherche à tromper. Le seuil de variance tolérable sans qu'elle devienne vecteur d'attribution est un paramètre de calibrage, pas une propriété émergente.

L'implication pratique : l'injection calibrée de variance non-opérationnelle (erreurs de registre mineures, silences imprévisibles, dérives de thématique) est nécessaire, mais sa calibration optimale est non triviale. Trop de variance réintroduit le signal d'imitation que le modèle cherche à éliminer. Trop peu de variance produit le signal de régularité paradoxale. Ce n'est pas un paramètre qu'on règle une fois : c'est une contrainte dynamique sur la durée d'opération.

Pour donner un ordre de grandeur de cette contrainte, considérons trois features comportementales : délai inter-posts, ratio type-token lexical par session, ratio d'engagement hebdomadaire. Pour un utilisateur organique, le coefficient de variation de ces features reflète la variabilité naturelle du comportement humain : les valeurs médianes se situent typiquement entre 0.4 et 1.2 selon la feature, avec un quantile $q_{0,05}$ (en deçà duquel un compte entre dans la zone de suspicion) entre 0.15 et 0.40. Un nœud opérant sans injection de variance produit des CV de l'ordre de 0.05 à 0.12, systématiquement sous $q_{0,05}$ pour l'ensemble des features. L'injection calibrée de bruit comportemental remonte ces valeurs vers la frontière du quantile critique, mais la fenêtre viable est structurellement étroite : un déficit de variance de 10 à 15 % sous le seuil organique suffit à placer le compte dans la queue détectable, tandis qu'un excès de même amplitude réintroduit les artefacts d'incohérence exploitables par les détecteurs de premier ordre.

Varol et al. [43] documentent que les features discriminantes les plus robustes pour la détection de bots sont les séries temporelles d'activité et les patterns d'engagement réseau, précisément les features que SAINTS calibre individuellement sur chaque persona. Cresci et al. [30] soulignent que les performances publiées des systèmes de détection de bots sont souvent surestimées sur des datasets non représentatifs, ce qui suggère que ce test de queue inférieure n'est pas encore déployé de manière opérationnelle fiable à grande échelle. C'est la surface où le modèle est le plus vulnérable à l'échelle individuelle, et la moins exploitée en pratique actuelle.

5.2 Analyse topologique du sous-graphe de validation

Pour le réseau de validation mutuelle, soit ρ_S la densité de liens du sous-graphe synthétique :

$$\rho_S = \frac{|E_S|}{\binom{|S|}{2}}$$

et $\rho_O(|S|)$ la densité attendue d'un sous-graphe aléatoire de taille $|S|$ tiré du réseau organique.

Condition de détection : $\rho_S \gg \rho_O(|S|)$ signale une communauté artificiellement dense.

La contrainte : les liens synthétiques-synthétiques doivent être suffisamment peu denses pour que $\rho_S \approx \rho_O(|S|)$, ce qui limite la vitesse de renforcement mutuel de crédibilité. Une construction de crédibilité rapide exige une validation croisée dense, ce qui augmente ρ_S vers la détectabilité. Le temps de maturation du réseau est borné inférieurement par cette contrainte.

L'opération Shrimp on the Barbie [16] constitue la confirmation empirique directe de ce vecteur. L'opération australienne pro-gouvernementale à topologie distribuée, avec personas dans des domaines thématiques distincts, a été détectée par analyse topologique du sous-graphe de validation : densité de liens fictif-fictif statistiquement improbable pour un réseau organique de cette taille. La structure était correcte ; la densité interne du sous-graphe ne l'était pas.

Waniek et al. [31] montrent qu’il est possible de masquer les nœuds centraux d’un réseau couvert à partir d’informations locales uniquement ; les mesures de centralité de groupe restent néanmoins exploitables. Ce résultat définit la limite théorique du camouflage topologique : on peut masquer qui commande, on peut difficilement masquer qu’un groupe existe si sa densité interne dépasse le plancher organique.

La tension fondamentale est structurellement irréductible : plus l’infrastructure cherche à construire de la crédibilité rapidement en créant des liens de validation croisée, plus elle se rend détectable par analyse topologique. La vitesse de montée en crédibilité et la résistance à la détection topologique sont en opposition directe. Ralentir la maturation est la seule résolution, à un coût opérationnel réel.

5.3 Convergence sémantique sous charge

Lorsque l’infrastructure est en mode opérationnel actif (et non en phase de maturation passive), les nœuds convergent thématiquement sur la cible de l’opération. Cette convergence crée un gradient sémantique inter-nœuds qui n’existe pas en phase passive. La fragmentation des actions en OAC limite la corrélation opérationnelle observable au niveau des actions individuelles, mais ne peut pas éliminer la convergence thématique inhérente à une opération ciblée sur un même sujet.

Cinquante nœuds opérant dans des domaines thématiques distincts en phase passive présentent une distribution sémantique cross-comptes conforme à l’attendu pour un ensemble d’utilisateurs organiques aux intérêts variés. Les mêmes cinquante nœuds, activés pendant une semaine sur une cible narrative unique, génèrent une distribution sémantique inter-nœuds anormalement homogène sur cette fenêtre. Ce n’est pas un artefact de la méthode de détection : c’est une propriété physique de l’opération. Pour influencer une cible narrative, les nœuds doivent parler de la cible narrative. Et parler de la même chose au même moment est précisément le signal que l’analyse topologique et sémantique conjointe cherche.

Luceri et al. [10] démontrent que les agents LLM en mode de coordination produisent des narratives plus homogènes et une adoption de hashtags plus rapide et plus soutenue que les configurations sans coordination, et que ce signal est présent même sans communication explicite entre agents, simplement via l’alignement d’objectifs. IOHunter [35] fusionne modèles de langage et réseaux de neurones sur graphes pour atteindre des performances d’état de l’art sur des campagnes de six pays simultanément, précisément parce qu’il opère sur la structure conjointe contenu-graphe, capturant exactement ce type de convergence sémantique sous charge.

La tension non résolue est structurelle : une infrastructure qui n’opère jamais activement ne converge jamais sémantiquement, mais elle ne produit pas non plus d’effet d’influence. L’activité opérationnelle est la condition nécessaire à l’utilité de l’infrastructure et à sa détectabilité par ce vecteur. Les OAC peuvent fragmenter les actions, mais ils ne peuvent pas fragmenter l’intention narrative sur une fenêtre temporelle. La cadence opérationnelle optimale (fréquence d’activation suffisante pour produire de l’impact, insuffisante pour produire de la convergence sémantique détectable) est un paramètre de calibrage fin que ce modèle ne résout pas.

Le vecteur n’est pas directement actionnable sans accès plateforme pour l’analyse sémantique cross-comptes en temps réel. Il constitue néanmoins une surface de détection réelle pour les acteurs disposant de cet accès : principalement les plateformes elles-mêmes et les agences de renseignement en coopération avec elles.

5.4 Vecteur humain et fatigue OPSEC

Le LLM maintient une identité avec une cohérence que l’humain ne peut pas égaler sur durée longue. L’inverse est vrai dès que l’opération bascule en mode actif. L’humain qui reprend la main n’est pas Marc. Il connaît Marc (stylométrie, habitudes, références), mais il les applique

sous charge cognitive, sous contrainte temporelle, dans un contexte imprévisible. La dérive est non-intentionnelle. Elle n'en est pas moins détectable.

Ceci est formalisé dans le terme $\eta(t)$ du modèle de distance stylométrique de la section 3.2. La propriété clé est que $\eta(t)$ est croissant dans le temps : la fatigue OPSEC est un processus de dégradation monotone sur durée longue. Un opérateur maintient une discipline stricte au démarrage. Sur plusieurs années, les protocoles deviennent des habitudes, les habitudes produisent des raccourcis, les raccourcis produisent des artefacts. Cette dégradation est statistiquement inévitable à l'échelle d'un parc d'opérateurs. L'architecture ne peut pas y remédier.

Indian Chronicles en est la confirmation empirique la plus nette [13]. Quinze ans d'opération, 750 faux médias dans 119 pays ; ce réseau a été compromis non par analyse comportementale des personas, mais par une seule adresse email centrale liant des centaines de domaines. Ce n'est pas une erreur d'implémentation. C'est la structure du problème : une organisation humaine opérant sur durée longue à l'échelle cherche l'efficacité, et l'efficacité produit des corrélations.

La surface est irréductible parce qu'elle n'est pas dans le modèle ; elle est dans ce que le modèle ne contrôle pas. Un opérateur qui parle. Un artefact de synchronisation sur une opération mal planifiée. Une trace qui émerge dans un contexte non lié. Historiquement, les infrastructures de ce niveau ont cédé à ces points, jamais par investigation proactive systématique.

L'implication défensive est non triviale : la patience est la stratégie défensive la plus symétrique à cette architecture. Elle ne requiert pas de capacités analytiques supérieures à celles de l'adversaire. Elle exige seulement de maintenir une surveillance persistante jusqu'à la matérialisation inévitable de l'erreur humaine.

5.5 Trace physique et financière

L'infrastructure physique laisse une trace de deux natures distinctes.

La trace matérielle : l'équipement grand public diversifié par sources d'acquisition répond au problème de corrélation d'empreinte hardware. Elle ne répond pas à la corrélation financière. Des transactions dispersées sur des années via canaux informels, individus tiers, matériel d'occasion, résistent bien aux analyses automatisées. Elles résistent moins bien à une investigation judiciaire ciblée disposant d'un signal de départ.

La trace financière : abonnements réseau, licences logicielles, acquisitions matérielles. Ces transactions sont corrélables si elles convergent vers une même entité : comptable, bancaire, ou personnelle. Une perquisition ne commence pas toujours par le réseau. Elle commence souvent par la comptabilité. C'est par cette surface qu'Indian Chronicles a été déconstruit : les enregistrements de domaines convergeaient vers une entité centrale traçable.

Ces deux surfaces (hardware et financière) sont distinctes et exigent des réponses distinctes. La diversification des sources d'acquisition répond à l'une. Elle ne répond pas à l'autre. Et les deux ensemble ne répondent pas à un contexte où le levier est judiciaire et non analytique, contexte dans lequel le seuil d'action n'est pas la preuve statistique mais l'inculpation.

L'implication pour les défenseurs : dans les contextes où l'investigation judiciaire est envisageable, la piste financière et comptable précède souvent la piste réseau comme vecteur d'entrée. Les agences ayant la patience de disperser les acquisitions sur des années via canaux informels peuvent résoudre cette surface ; le délai de maturation est néanmoins lui-même un coût réel qui entre dans le budget opérationnel total.

Le tableau 1 synthétise l'actionnabilité de chaque surface par type d'acteur défensif. L'objectif n'est pas de prescrire un pipeline de détection complet, mais de permettre à chaque acteur de prioriser les surfaces sur lesquelles ses capacités propres ont une prise réelle.

TABLE 1 – Actionnabilité des surfaces de détection par acteur défensif

Surface	Plateforme	CERT / SOC	Renseignement	LEA / Judiciaire
5.1 Régularité paradoxale	Test queue inférieure CV comportemental. Intégrable au scoring automatisé.	Requiert coopération plateforme pour accès aux features individuelles.	Exploitable via partenariat plateforme sur cibles préalablement identifiées.	Non actionnable directement.
5.2 Densité topologique	Analyse de graphe communautaire. Détection de sous-graphes anormalement denses. Actionnable à grande échelle.	Analyse OSINT sur graphes publics. Profondeur limitée sans accès interne.	Corrélation multi-plateforme via partenariats institutionnels.	Non actionnable directement.
5.3 Convergence sémantique	Analyse sémantique cross-comptes en temps réel. Actionnable avec accès aux données internes.	NLP sur corpus publics. Signal faible sans volume suffisant.	Corrélation narrative avec objectifs géopolitiques connus. Orientation analytique.	Non actionnable directement.
5.4 Vecteur humain	Surveillance passive longue durée. Capitalisation d'anomalies ponctuelles.	Capitalisation inter-incidents. Partage d'indicateurs entre acteurs.	HUMINT. Patience stratégique. Vecteur principal pour cette surface.	Exploitation d'erreurs humaines documentées comme point d'entrée.
5.5 Trace physico-financière	Limité. Pas d'accès aux données financières ou comptables.	Limité. Pas de levier direct.	Surveillance financière. Corrélation d'acquisitions matérielles sur durée longue.	Perquisition comptable. Corrélation de domaines. Vecteur principal d'entrée.

6 Limites et travaux futurs

Ce que le modèle ne couvre pas. La couche humaine de contrôle n'est pas formalisée. L'architecture SAINTS modélise les nœuds autonomes en opération passive et les interactions humaines en opération active comme deux régimes distincts, sans formaliser la dynamique de transition entre eux ni la structure organisationnelle du layer opérateur. L'analyse identifie qu'un opérateur par identité est une exigence non-négociable lors des phases actives : un programme multi-identités produirait une désynchronisation par économie d'attention. Mais la structure organisationnelle qui garantit ce rapport 1 :1 sur durée longue, avec rotation et compartimentation, n'est pas modélisée. C'est précisément cette structure qui est la source des fuites documentées historiquement ; son absence du modèle est une limite réelle, non un choix de simplification.

La convergence sémantique inter-nœuds sous charge opérationnelle est identifiée comme surface de détection (section 5.3) mais n'est pas formalisée quantitativement. Un modèle de la distribution sémantique cross-comptes en fonction du régime opérationnel (passif vs. actif) et de l'intensité narrative cible permettrait de dériver un test statistique actionnable, du type : à partir de quel niveau d'activation opérationnelle le gradient sémantique inter-nœuds dépasse le seuil de détectabilité ? Cette formalisation exige un modèle de la diversité sémantique organique sur le sujet cible comme baseline de comparaison, et constitue une question ouverte de ce travail.

La contre-détection par machine learning adversarial n'est pas adressée. Le modèle SAINTS fait l'hypothèse implicite que les seuils d'extraction des systèmes de surveillance restent stables dans le temps. Cette hypothèse est fragile : un système d'analyse capable d'apprentissage continu sur corpus massifs de comportements synthétiques peut abaisser ces seuils sans signal préalable et sans alerte à l'opérateur adverse. Dans ce cas, le mécanisme de saturation tel que formalisé se retourne : les nœuds produisant exactement le bruit attendu deviennent un corpus d'entraînement pour le détecteur, qui apprend précisément à distinguer ce bruit calibré du bruit organique authentiquement aléatoire. Ce cas redresse l'asymétrie dans une direction défavorable à l'attaquant et n'est pas traité formellement ici.

L'identité construite sur un individu réel décédé dont le décès n'a pas été enregistré publiquement élimine la surface du passé manquant. Indian Chronicles [13] a précisément utilisé ce vecteur, réactivant des NGO accréditées aux Nations Unies dont les fondateurs étaient décédés. La détection exige une corrélation entre registres d'état civil non-numérisés et comportement en ligne, deux sources hétérogènes rarement corrélées automatiquement, exigeant une intervention humaine spécialisée qui ne s'initie jamais sans raison préalable.

Ce que la littérature confirme comme trajectoire. Luceri et al. [10] démontrent que des agents LLM génératifs peuvent reproduire, sans orchestration humaine, les signatures de coordination caractéristiques des OI réelles : réseaux plus denses, interactions plus réciproques, narratives plus homogènes, adoption de hashtags plus rapide. Résultat remarquable : la simple révélation aux agents de quels autres agents partagent leurs objectifs produit des niveaux de coordination presque équivalents à ceux obtenus par délibération explicite et vote collectif. L'implication est que les campagnes futures pourraient ne requérir qu'une diffusion d'objectifs, pas d'instructions opérationnelles, réduisant drastiquement la surface de communication détectable entre les nœuds. Le rapport Mandiant [11] situe 2025 comme le moment de bascule de « l'IA comme outil de productivité » vers « l'IA comme infrastructure opérationnelle », dans le contexte des opérations cyber et d'influence. La classe de menace formalisée dans SAINTS n'est pas hypothétique : les composantes techniques sont disponibles, leur assemblage suit une trajectoire documentée par ces sources convergentes.

Les rapports OpenAI [9] et Google Threat Intelligence Group [40] offrent une donnée empirique convergente dans ce contexte : toutes les opérations documentées qui exploitaient les modèles OpenAI via API étaient détectables précisément parce qu'elles dépendaient de cette API centralisée. L'opération A2Z a cessé son activité immédiatement après son bannissement du service. Une infrastructure à inférence locale intégrale élimine ce point de défaillance unique,

ce qui est précisément la propriété architecturale que SAINTS formalise. Ces rapports documentent l'état actuel, non l'état futur vers lequel la trajectoire converge.

Travaux futurs prioritaires. La simulation de la détectabilité du sous-graphe synthétique en fonction de k , ρ_S , et des paramètres du test KS permettrait de dériver une courbe empirique $k^* \rightarrow P(\text{détection})$ pour différentes configurations de plateforme. Ce travail permettrait aux défenseurs de calibrer leurs ressources d'investigation sur la base d'un modèle probabiliste plutôt que d'heuristiques ad hoc. Le cadre de simulation génératif développé par Luceri et al. [10] constitue un point de départ utilisable : des sous-graphes synthétiques SAINTS pourraient être injectés dans les environnements de simulation existants et soumis aux algorithmes de détection décrits en section 2.2 pour mesurer les taux de faux négatifs en fonction de la taille k et de la densité ρ_S .

Un traitement formel game-théorique de la dynamique attaquant-défenseur sur durée longue constitue le deuxième axe prioritaire. Ce modèle devrait intégrer explicitement les stratégies de patience des deux parties : l'attaquant attendant la fenêtre opérationnelle sans produire de signal corrélable, le défenseur attendant l'erreur humaine inévitable. La théorie des jeux répétés avec information incomplète est le cadre naturel, mais sa calibration empirique sur les paramètres de coût dérivés de la section 4 reste à faire. Waniek et al. [31] offrent des éléments de formalisme sur la structure des réseaux opaques qui pourraient être étendus dans cette direction.

7 Conclusion

La robustesse de cette infrastructure n'est pas dans son imperméabilité technique. Elle est dans le fait qu'elle ne justifie jamais économiquement l'investigation qui permettrait de la démanteler. Le seuil k^* (au-delà duquel le coût d'investigation dépasse les budgets défenseurs disponibles rapporté à la probabilité de succès) est l'objet analytique central que ce papier formalise. En deçà de k^* , une investigation ciblée reste viable si un signal de départ externe existe. Au-delà, la seule stratégie rationnelle est d'attendre.

La formalisation produite dans ce travail a trois implications opérationnelles directes.

Les méthodes de détection actuelles (graphe de similarité comportementale, analyse temporelle de micro-coordination, scoring comportemental côté plateforme) restent valides mais ne sont plus suffisantes pour cette classe d'infrastructure. Leur hypothèse fondatrice (la coordination laisse des traces corrélables) est précisément la propriété que SAINTS élimine par construction. Les défenseurs qui calibrent leurs seuils de détection sur ces méthodes se retrouvent avec un appareil défensif dont la cible a changé de nature sans que les instruments aient changé. Le passage aux statistiques de second ordre (variance comportementale, distributions de corrélation inter-comptes, densité topologique des sous-graphes) n'est pas une optimisation de l'existant. C'est un changement de paradigme de détection.

Le travail analytique le plus rentable pour un défenseur sous contrainte de ressources n'est pas l'investigation de comptes individuels suspects. C'est la cartographie des surfaces où l'architecture reste vulnérable (sections 5.1 à 5.5), la quantification de k^* pour sa propre configuration de ressources, et la décision rationnelle sur l'allocation : investigation active vs. surveillance passive en attente de l'erreur humaine. Cette décision n'est pas rhétorique. Elle engage des ressources réelles, et le modèle développé ici fournit le cadre pour la prendre sur des bases formelles plutôt que sur des heuristiques.

La patience est le seul vecteur défensif réellement symétrique à cette architecture. L'erreur humaine est inévitable, imprévisible, et structurellement non-architecturable. Aucun système suffisamment déployé sur durée longue, avec des opérateurs sous contrainte, ne maintient une discipline parfaite indéfiniment. C'est là que les infrastructures de ce niveau ont historiquement cédé : Secondary Infection par l'adresse email réutilisée, Indian Chronicles par l'adresse email centrale, l'IRA par des agents qui ont maintenu des contacts traçables. La patience n'est pas

un aveu d'impuissance. C'est la reconnaissance que la limite structurelle de cette classe d'infrastructure n'est pas dans ses composantes techniques (toutes disponibles et en amélioration constante), mais dans le facteur humain de contrôle qu'elle ne peut pas éliminer.

Références

- [1] D. Pacheco, P.-M. Hui, C. Torres-Lugo, B. T. Truong, A. Flammini, F. Menczer. *Uncovering Coordinated Networks on Social Media : Methods and Case Studies*. AAAI ICWSM 2021. <https://doi.org/10.1609/icwsm.v15i1.18075>
- [2] L. Luceri, V. Pantè, K. Burghardt, E. Ferrara. *Unmasking the Web of Deceit : Uncovering Coordinated Activity to Expose Information Operations on Twitter*. ACM Web Conference (WWW) 2024. <https://doi.org/10.1145/3589334.3645529>
- [3] F. Giglietto, N. Righetti, L. Rossi, G. Marino. *It takes a village to manipulate the media : coordinated link sharing behavior during 2018 and 2019 Italian elections*. Information, Communication & Society, 23(10), 2020. <https://doi.org/10.1080/1369118X.2020.1739732>
- [4] L. Iannucci, E. Muratore, A. Matakos, M. Kivelä. *Detecting Coordinated Activities Through Temporal, Multiplex, and Collaborative Analysis*. arXiv :2512.19677, 2025. <https://doi.org/10.48550/arXiv.2512.19677>
- [5] S. Somin, T. Cohen, J. Kepner, A. Pentland. *Echoes of the hidden : Uncovering coordination beyond network structure*. arXiv :2504.02757, 2025. <https://doi.org/10.48550/arXiv.2504.02757>
- [6] Meta Transparency. Adversarial Threat Reports, 2019–2024. <https://transparency.fb.com/metasecurity/threat-reporting>
- [7] B. He, Y. Yang, Q. Wu et al. *BotDGT : Dynamicity-aware Social Bot Detection with Dynamic Graph Transformers*. arXiv :2404.15070, 2024. <https://doi.org/10.48550/arXiv.2404.15070>
- [8] US Senate Select Committee on Intelligence. *Russian Active Measures Campaigns and Interference in the 2016 US Election, Volume 2*. 2019. <https://www.intelligence.senate.gov/wp-content/uploads/2024/08/sites-default-files-documents-report-volume2.pdf>
- [9] OpenAI. *Influence and Cyber Operations : An Update*. Octobre 2024. https://cdn.openai.com/threat-intelligence-reports/influence-and-cyber-operations-an-update_October-2024.pdf
- [10] G. M. Orlando, J. Ye, V. La Gatta, M. Saeedi, V. Moscato, E. Ferrara, L. Luceri. *Emergent Coordinated Behaviors in Networked LLM Agents : Modeling the Strategic Dynamics of Information Operations*. The Web Conference (WWW) 2026. arXiv :2510.25003. <https://doi.org/10.48550/arXiv.2510.25003>
- [11] Mandiant / Google Cloud. *AI Risk and Resilience : A Mandiant Special Report*. Mars 2026. <https://cloud.google.com/security/resources/ai-risk-and-resilience>
- [12] Graphika / EU DisinfoLab / DFRLab. *Secondary Infektion*. Mai 2020. <https://secondaryinfektion.org/downloads/secondary-infektion-report.pdf>
- [13] EU DisinfoLab. *Indian Chronicles : Deep Dive into a 15-Year Operation Targeting the EU and United Nations*. Décembre 2020. <https://www.disinfobservatory.org/download/26544>
- [14] Citizen Lab. *Burned After Reading : Endless Mayfly's Ephemeral Disinformation Campaign*. Mai 2019. <https://citizenlab.ca/2019/05/burned-after-reading-endless-mayflies-ephemeral-disinformation-campaign>
- [15] EU DisinfoLab / Qurium. *Doppelganger*. Septembre 2022. <https://www.disinfo.eu/doppelganger-hub/>
- [16] Graphika / Stanford Internet Observatory. *Shrimp on the Barbie*. 2020. <https://graphika.com/reports/shrimp-on-the-barbie>
- [17] Y. Yang, R. Paudel, J. McShan et al. *Coordinated link sharing on Facebook*. Scientific Reports 15, 15335, 2025. <https://doi.org/10.1038/s41598-025-00233-w>
- [18] M. Brennan, R. Greenstadt. *Practical Attacks Against Authorship Recognition Techniques*. AAAI Workshop, 2009. <https://www.semanticscholar.org/paper/0d39ee9970ff6fa84620f7f9a96c884d164817c6>

- [19] M. Brennan, S. Afroz, R. Greenstadt. *Adversarial Stylometry : Circumventing Authorship Recognition to Preserve Privacy and Anonymity*. ACM TISSEC, 15(3), 2012. <https://doi.org/10.1145/2382448.2382450>
- [20] K. Alperin, R. Leekha, A. Uchendu et al. *Masks and Mimicry : Strategic Obfuscation and Impersonation Attacks on Authorship Verification*. arXiv :2503.19099, 2025. <https://doi.org/10.48550/arXiv.2503.19099>
- [21] E. Mitchell, Y. Lee, A. Khazatsky, C. D. Manning, C. Finn. *DetectGPT : Zero-Shot Machine-Generated Text Detection using Probability Curvature*. ICML 2023. <https://doi.org/10.48550/arXiv.2301.11305>
- [22] A. Pedrotti, M. Papucci, C. Ciaccio et al. *Stress-testing Machine Generated Text Detection : Shifting Language Models Writing Style to Fool Detectors*. Findings of ACL 2025. <https://doi.org/10.48550/arXiv.2505.24523>
- [23] Y. Gu, S. Li, X. Hu. *MASH : Evading Black-Box AI-Generated Text Detectors via Style Humanization*. arXiv :2601.08564, 2026. <https://doi.org/10.48550/arXiv.2601.08564>
- [24] H. Zhang, B. L. Edelman, D. Francati et al. *Watermarks in the Sand : Impossibility of Strong Watermarking for Generative Models*. ICML 2024. <https://doi.org/10.48550/arXiv.2311.04378>
- [25] C. R. Jones, B. K. Bergen. *People cannot distinguish GPT-4 from a human in a Turing test*. arXiv :2405.08007, 2024. <https://doi.org/10.48550/arXiv.2405.08007>
- [26] G. Spitale, N. Biller-Andorno, F. Germani. *AI model GPT-3 (dis)informs us better than humans*. Science Advances, 9(26), 2023. <https://doi.org/10.1126/sciadv.adh1850>
- [27] I. Rathi, S. Taylor, B. K. Bergen, C. R. Jones. *GPT-4 is judged more human than humans in displaced and inverted Turing tests*. arXiv :2407.08853, 2024. <https://doi.org/10.48550/arXiv.2407.08853>
- [28] E. Vyborov, O. Osypenko, S. Sotnyk. *Exploring Fact Memorization and Style Imitation in LLMs Using QLoRA*. arXiv :2406.08582, 2024. <https://doi.org/10.48550/arXiv.2406.08582>
- [29] W. Li, J. Liu, A. Liu et al. *BIG5-CHAT : Shaping LLM Personalities Through Training on Human-Grounded Data*. arXiv :2410.16491, 2025. <https://doi.org/10.48550/arXiv.2410.16491>
- [30] S. Cresci, K.-C. Yang, A. Spognardi et al. *Demystifying Misconceptions in Social Bots Research*. arXiv :2303.17251, 2025. <https://doi.org/10.48550/arXiv.2303.17251>
- [31] M. Waniek, T. P. Michalak, M. Wooldridge, T. Rahwan. *How Members of Covert Networks Conceal the Identities of Their Leaders*. ACM TIST, 13 :1, Article 12, 2021. <https://doi.org/10.1145/3490462>
- [32] F. Cinus, M. Minici, L. Luceri, E. Ferrara. *Exposing Cross-Platform Coordinated Inauthentic Activity in the Run-Up to the 2024 U.S. Election*. ACM Web Conference (WWW) 2025. <https://doi.org/10.1145/3696410.3714698>
- [33] P. Piercey, R. Pearce, N. Veldt. *Coordinated Botnet Detection in Social Networks via Clustering Analysis*. ACM HPC '23 Workshop, 2023. <https://doi.org/10.1145/3605731.3608959>
- [34] T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer. *QLoRA : Efficient Finetuning of Quantized LLMs*. NeurIPS 2023. <https://doi.org/10.48550/arXiv.2305.14314>
- [35] M. Minici, L. Luceri, F. Fabbri, E. Ferrara. *IOHunter : Graph Foundation Model to Uncover Online Information Operations*. AAAI 2025. <https://doi.org/10.48550/arXiv.2412.14663>
- [36] T. Magelinski, L. H. X. Ng, K. M. Carley. *A Synchronized Action Framework for Responsible Detection of Coordination on Social Media*. Journal of Online Trust and Safety 1(2), 2022. <https://doi.org/10.54501/jots.v1i2.30>
- [37] D. A. Broniatowski, N. Gabriel, N. Johnson. *Inductive detection of influence operations via graph learning*. Scientific Reports 13, 22571, 2023. <https://doi.org/10.1038/s41598-023-49676-z>
- [38] J. Wu, S. Yang, R. Zhan, Y. Yuan, L. S. Chao, D. F. Wong. *A Survey on LLM-Generated Text Detection : Necessity, Methods, and Future Directions*. Computational Linguistics (MIT Press), 51(1), 2025. https://doi.org/10.1162/coli_a_00549
- [39] L. Mannocci, M. Mazza, A. Monreale, M. Tesconi, S. Cresci. *Detection and Characterization of Coordinated Online Behavior : A Survey*. arXiv :2408.01257, 2024. <https://doi.org/10.48550/arXiv.2408.01257>
- [40] Google Threat Intelligence Group. *Adversarial Misuse of Generative AI*. Janvier 2025. <https://cloud.google.com/blog/topics/threat-intelligence/adversarial-misuse-generative-ai>

- [41] M. Matteo Cinelli, S. Cresci, W. Quattrociocchi et al. *Coordinated Inauthentic Behavior and Information Spreading on Twitter*. arXiv :2503.15720, 2025. <https://doi.org/10.48550/arXiv.2503.15720>
- [42] H. McGovern, R. Stureborg, Y. Suhara, D. Alikaniotis. *Your Large Language Models Are Leaving Fingerprints*. arXiv :2405.14057, 2024. <https://doi.org/10.48550/arXiv.2405.14057>
- [43] O. Varol, E. Ferrara, C. A. Davis, F. Menczer, A. Flammini. *Online Human-Bot Interactions : Detection, Estimation, and Characterization*. ICWSM 2017. <https://doi.org/10.1609/icwsm.v11i1.14871>
- [44] R. Overdorf, R. Greenstadt. *Blogs, Twitter Feeds, and Reddit Comments : Cross-Domain Authorship Attribution*. PoPETS 2016(3). <https://doi.org/10.1515/popets-2016-0021>
- [45] I. Ariyaratne, G. Ariyaratne, A. Flammini, F. Menczer, A. C. Nwala. *Behavior Change as a Signal for Identifying Social Media Manipulation*. arXiv, 2026.
- [46] Recorded Future / Insikt Group. *Stimmen aus Moskau : Russian Influence Operations Target German Elections*. Février 2025. <https://www.recordedfuture.com/research/stimmen-aus-moskau-russian-influence-operations-target-german-elections>

Déclaration d’usage d’IA. Ce travail a mobilisé un pipeline intégrant Claude Opus (Anthropic), Qwen 3 en configuration multi-agents et Perplexity, couvrant la formalisation, la recherche documentaire et la production du document.